

Московский государственный университет имени М. В. Ломоносова  
Факультет вычислительной математики и кибернетики  
Кафедра математических методов прогнозирования

Васильев Руслан Леонидович

# Калибровка уверенности нейронных сетей

КУРСОВАЯ РАБОТА

**Научный руководитель:**

д.ф-м.н., профессор

*А. Г. Дьяконов*

Москва, 2021

# Содержание

<b>1</b>	<b>Введение</b>	<b>2</b>
<b>2</b>	<b>Постановка задачи</b>	<b>2</b>
<b>3</b>	<b>Оценка откалиброванности</b>	<b>3</b>
3.1	Визуализация	3
3.2	Метрики	5
<b>4</b>	<b>Методы калибровки</b>	<b>6</b>
4.1	Постобработка	6
4.1.1	Гистограммный биннинг (Histogram binning)	6
4.1.2	Изотоническая регрессия (Isotonic regression)	7
4.1.3	Калибровка Платта (Platt Calibration) и ее обобщения	7
4.2	Калибровка на этапе обучения	8
4.2.1	Сглаживание меток (Label smoothing)	9
4.2.2	Фокальная ошибка (Focal loss)	9
<b>5</b>	<b>Вычислительные эксперименты</b>	<b>10</b>
5.1	Дизайн экспериментов	10
5.2	Результаты	11
<b>6</b>	<b>Заключение</b>	<b>14</b>
	<b>Список литературы</b>	<b>15</b>
	<b>Приложения</b>	<b>17</b>
<b>A</b>	<b>Качество классификации моделей</b>	<b>17</b>
<b>B</b>	<b>Биннинговые метрики</b>	<b>19</b>
<b>C</b>	<b>Скоринговые ошибки</b>	<b>25</b>

# 1 Введение

Количество областей, в которых используется глубокое обучение, стремительно растет. Нейронные сети активно применяются для диагностики заболеваний по медицинским изображениям [1], используются в алгоритмах управления беспилотными автомобилями [2], а также для машинного перевода [3].

Для подобных задач важно не только обучить модель выдавать корректное предсказание, но и получить степень уверенности в нем. Под *уверенностью* понимается оценка вероятности прогноза. Например, если алгоритм для большой выборки пациентов предсказывает, что они здоровы с вероятностью 0.9, то мы ожидаем, что 90% из них действительно окажутся здоровыми. Модель, выдающая достоверные вероятности, называется *откалиброванной*. Откалиброванность важна не только для интерпретации предсказаний нейросетей, но и для использования оценок другими алгоритмами, например, в языковых моделях [4].

Современные нейронные сети нередко оказываются плохо откалиброванными [5]. Тем не менее смещенные оценки вероятностей выдают многие алгоритмы машинного обучения [6, 7]. Для «классических» моделей были предложены различные техники калибровки, некоторые из которых получили развитие в нейронных сетях.

## 2 Постановка задачи

Пусть решается задача классификации объектов из множества  $\mathcal{X}$  с классами  $\mathcal{Y} = \{1, \dots, K\}$ . Предположим, что мы обучили *модель* – алгоритм, который для каждого  $x \in \mathcal{X}$  выдает вектор оценок – *уверенностей* (confidences)  $\mathbf{a}(x) = (a_1(x), \dots, a_K(x))$ ,  $\sum_{j=1}^K a_j(x) = 1$ . Далее объекту приписывается класс, соответствующий наибольшей уверенности:

$$\hat{y}(x) := \operatorname{argmax}_{j \in \mathcal{Y}} a_j, \quad \hat{p}(x) := a_{\hat{y}}.$$

Оценку  $\hat{p}$  мы бы хотели трактовать как вероятность того, истинная метка  $y$  совпадает с предсказанной  $\hat{y}$ . Если наша оценка достаточно точна, то модель называют *откалиброванной*. Формально определение *откалиброванности* (в [5] – **perfect calibration**) можно записать следующим образом:

$$\mathbb{P}(y = \hat{y} \mid \hat{p} = p) = p \quad \forall p \in [0, 1]. \quad (1)$$

Существуют и более сильные определения откалиброванности модели, чем (1). Например, согласно [8] классификатор называется откалиброванным (в оригинале – **well-calibrated**), если

$$\mathbb{P}(y = j \mid a_j = p) = p \quad \forall j \in \mathcal{Y}, \quad \forall p \in [0, 1], \quad (2)$$

то есть мы ожидаем, что уверенности, выдаваемые для каждого класса (а не только предсказанного), являются откалиброванными.

В случае реальных данных и моделей мы не можем напрямую проверить (1) и (2), поэтому на помощь приходят различные метрики и визуализации, которые будут рассмотрены в разд. 3.

В разд. 4 описываются методы, с помощью получить откалиброванную модель. Во-первых, можно *откалибровать* уверенности, то есть найти функцию, отображающую смещенные оценки уверенности в откалиброванные. Поиск наилучшего отображения достаточно нетривиален. Во-вторых, можно применять различные техники на этапе обучения для получения откалиброванной модели, среди которых выделяются модификации функции потерь.

В разд. 5 приводится сравнение реализованных методов калибровки для современных архитектур нейронных сетей.

## 3 Оценка откалиброванности

### 3.1 Визуализация

Покажем, как можно оценить откалиброванность модели в реальных задачах. Для начала упростим задачу до *бинарной классификации*:  $\mathcal{Y} = \{0, 1\}$  – пусть наша модель выдает *уверенности*  $\hat{p}$  в том, что объект принадлежит положительному классу (под *положительным* понимается  $y = 1$ ). Бинарная классификация чаще встречается при использовании «классических» алгоритмов машинного обучения: логистическая регрессия, решающий лес, градиентный бустинг над деревьями, наивный байесовский классификатор, метод опорных векторов и другие – проблемы их калибровки подробно рассматривались в [6, 7].




Рис. 1: Варианты визуализации надежности алгоритма. Для наглядности были сгенерированы синтетические данные, в качестве модели использован SVM: расстояния до разделяющей гиперплоскости отмасштабированы на  $[0, 1]$ .

Разобьем множество значений уверенностей  $[0, 1]$  на  $M$  интервалов  $I_m$  равной

ширины:

$$I_1 = \left[0, \frac{1}{M}\right), I_2 = \left[\frac{1}{M}, \frac{2}{M}\right), \dots, I_{M-1} = \left[\frac{M-2}{M}, \frac{M-1}{M}\right), I_M = \left[\frac{M-1}{M}, 1\right]. \quad (3)$$

Обозначим  $B_m$  множество индексов тех объектов выборки, значение уверенности для которых лежит в пределах  $I_m$ . Будем взаимозаменяемо называть  $B_m$  и соответствующие им интервалы  $I_m$  **бинами (bins)**.

В каждом бине  $B_m$  посчитаем долю объектов положительного класса  $A_m^1$  (**positive frequency**) и среднюю уверенность  $C_m^1$  (**confidence**) в том, что объект принадлежит положительному классу:

$$A_m^1 = \frac{1}{|B_m|} \sum_{i \in B_m} \mathbb{1}(y_i = 1), \quad C_m^1 = \frac{1}{|B_m|} \sum_{i \in B_m} \hat{p}_i \quad (4)$$

Далее построим график  $(C_m^1, A_m^1)_{m=1}^M$ . В итоге получим *график надежности* [9, 6] (**reliability plot/diagram**) – [рис. 1](#) (а). Также полученную кривую иногда называют *калибровочной кривой (calibration curve)*. Хорошей откалиброванности соответствует кривая, близкая к диагональной.

Можно отобразить полученные оценки в форме гистограммы – *диаграмме надежности*: на [рис. 1](#) (b) красным показывается средняя уверенность, синим – доля объектов положительного класса, попавших в бин. Если красный столбец выше синего, то алгоритм выдает недостаточно уверенные оценки (**underconfidence**), если синий выше красного – слишком большие (**overconfidence**). Дополнительно на том же графике мы покажем зеленым *вес бина (weight)* – долю объектов (всех классов), попавших в бин.

В случае, когда классов  $n > 2$ , диаграммы надежности строятся иначе. Наиболее популярный подход соответствует пониманию откалиброванности в смысле (1). Для каждого бина  $B_m$  оценивается точность (доля правильных ответов, **accuracy**)  $A_m$  и средняя уверенность в предсказании  $C_m$ :

$$A_m = \frac{1}{|B_m|} \sum_{i \in B_m} \mathbb{1}(y_i = \hat{y}_i), \quad C_m = \frac{1}{|B_m|} \sum_{i \in B_m} \hat{p}_i \quad (5)$$

(4) и (5) отличаются тем, что в многоклассовом случае  $\hat{y}_i$  и  $\hat{p}_i$  соответствуют предсказанному классу и уверенности, в то время как в бинарном варианте все считается для положительного класса. Заметим, что  $A_m$  и  $C_m$  оценивают соответственно левую и правую части (1). Их можно изобразить на диаграмме надежности. Для двух классов такой подход проиллюстрирован на [рис. 1](#) (с) – бины с границами  $< 0.5$  оказываются пустыми, поскольку в бинарной классификации алгоритм относит объект к классу, уверенность в котором  $> 0.5$ .

В [10] также предлагается встроить поклассовые диаграммы надежности (**classwise-reliability diagrams**): для этого мы каждый класс по отдельности объявляем положительным и строим  $n$  диаграмм надежности для бинарного случая. И хотя поклассовый подход более полный (2), для большого числа классов (например, 1000 в датасете Imagenet [11]) строить так много графиков будет затруднительно. Поэтому почти всегда используются диаграммы надежности для предсказанных классов (5).

## 3.2 Метрики

Кроме визуализаций, оценить откалиброванность модели помогают различные метрики. Одна из наиболее популярных — ECE (**Expected Calibration Error** [12]). Она приближает

$$\mathbb{E}_{\hat{p}} |\mathbb{P}(y = \hat{y} \mid \hat{p}) - \hat{p}|$$

с помощью разделения уверенностей по бинам ( $l$  – общее число объектов):

$$\begin{aligned} \text{ECE} &= \sum_{m=1}^M \frac{|B_m|}{n} |A_m - C_m| \\ &= \sum_{m=1}^M \frac{|B_m|}{n} \left| \frac{1}{|B_m|} \sum_{i \in B_m} \mathbb{1}(y_i = \hat{y}_i) - \frac{1}{|B_m|} \sum_{i \in B_m} \hat{p}_i \right| \\ &= \frac{1}{n} \sum_{m=1}^M \left| \sum_{i \in B_m} \mathbb{1}(y_i = \hat{y}_i) - \sum_{i \in B_m} \hat{p}_i \right|. \end{aligned} \quad (6)$$

Сравнивая (6) и диаграммы надежности для многоклассовой задачи, замечаем, что ECE в точности равна взвешенному среднему длин отрезков между красными и синими столбцами.

Существуют и другие метрики на основе разбиения уверенностей по бинам, хоть и используются значительно реже. Например, можно посчитать длину максимального разрыва между уверенностью и точностью [12]:

$$\text{MCE} = \max_m |A_m - C_m|, \quad (7)$$

или же учитывать уверенности не только за предсказанный класс, но и за все остальные (**classwise ECE**) [10]:

$$\text{cwECE} = \frac{1}{K} \sum_{j=1}^K \sum_{m=1}^M \frac{|B_m^j|}{n} |A_m^j - C_m^j|, \quad (8)$$

где  $B_m^j$ ,  $A_m^j$ ,  $C_m^j$  – соответственно  $m$ -й бин, точность и уверенность, если мы выделяем  $j$ -й класс как положительный, а все остальные собираем в отрицательный (то есть метрика соответствует покласовым диаграммам надежности).

Вместо равноширинных бинов (3) можно использовать равномошные бины — иногда таким образом строят диаграммы уверенности. В [13] предлагалось с помощью равномошных бинов считать и описанные ранее метрики. Далее везде будет использоваться равноширинная схема. Также, кроме  $l_1$ -нормы (т.е. усреднения модулей), можно использовать  $l_2$  (брать среднеквадратическое) [14].

Помимо биннинговых метрик, для оценки откалиброванности модели можно использовать *скоринговые функции ошибки* (**proper scoring rules**). Мы будем считать NLL (**Negative Log-Likelihood**):

$$\text{NLL} = -\frac{1}{l} \sum_{i=1}^n \log a_{i, y_i}, \quad (9)$$

где  $y_i$  – истинная метка класса  $i$ -го объекта,  $a_{i,y_i}$  – уверенность алгоритма в ней,  $n$  – общее число объектов,  $K$  – число классов. А также будем считать средний квадрат отклонения (BS – **Brier Score**):

$$\text{BS} = \frac{1}{n} \sum_{i=1}^n \sum_{j=1}^K (a_{ij} - \mathbb{1}(y_i = j))^2. \quad (10)$$

## 4 Методы калибровки

Методы калибровки можно разделить на две основные группы. Во-первых, можно сделать *постобработку* (**post-hoc calibration methods**) выходов модели. Для этого используется *функция деформации* (**calibration map**) — отображение, заменяющее смещенные оценки вероятности на откалиброванные. Ко второй группе относят методы, применяющиеся на этапе обучения модели.

### 4.1 Постобработка

Поиск функции деформации выполняется на *отложенной выборке*  $(x_i, y_i)_{i=1}^n$ . Обычно используется тот же набор данных, на которой валидируется модель и подбираются гиперпараметры.




Рис. 2: Визуализация различных функций деформации для бинарной классификации (те же данные и модель, что и на [рис. 1](#))

#### 4.1.1 Гистограммный биннинг (Histogram binning)

Изначально метод был предложен в [15] для калибровки решающих деревьев и наивного байесовского классификатора. Рассмотрим бинарный случай: ищется кусочно-постоянная функция деформации. А именно, множество значений выходных уверенностей разбивается на бины  $B_1, \dots, B_M$  (обычно равноширинные (3) или равномошные) и оценки, попавшие в  $B_m$ , заменяются на общую для данного бина  $\theta_m$ . Чтобы найти  $\theta_1, \dots, \theta_M$ , решается следующая задача оптимизации:

$$\sum_{m=1}^M \sum_{i \in B_m} (\theta_m - y_i)^2 \rightarrow \min_{\theta_1, \dots, \theta_M} \quad (11)$$

В такой постановке  $\theta_m$  будет равна доле объектов отложенной выборки положительного класса, попавших в бин  $B_m$ . Функция деформации проиллюстрирована на [рис. 2 \(a\)](#).

Метод обобщается на многоклассовый случай с помощью стратегии *один-против-всех* (**one-vs-rest**): каждый класс по отдельности объявляется положительным и строится  $K$  кусочно-постоянных функций деформации. На этапе применения выходной вектор вероятностей нормализуется.

#### 4.1.2 Изотоническая регрессия (Isotonic regression)

Метод предложен в [8]. Для бинарного случая по отложенной выборке тоже ищется кусочно-постоянная функция деформации, но число интервалов  $M$  и их границы оптимизируются, а на саму функцию дополнительно накладывается требование неубывания. Таким образом, решается следующая задача:

$$\sum_{m=1}^M \sum_{i \in \tilde{B}_m} (\theta_m - y_i)^2 \rightarrow \min_{\substack{M \\ \theta_1 \leq \dots \leq \theta_M \\ 0 = \alpha_0 \leq \alpha_1 \leq \dots \leq \alpha_{M-1} \leq \alpha_M = 1}} \quad (12)$$

где  $\tilde{B}_1 = \{i : \alpha_0 \leq \hat{p}_i < \alpha_1\}, \dots, \tilde{B}_m = \{i : \alpha_{m-1} \leq \hat{p}_i \leq \alpha_m\}$ . Вид функции проиллюстрирован на [рис. 2](#).

Изотоническая регрессия обобщается на многоклассовый случай так же, как и гистограммный биннинг.

#### 4.1.3 Калибровка Платта (Platt Calibration) и ее обобщения

Изначально метод предложен в [16] для калибровки метода опорных векторов. Как видно на иллюстрациях [рис. 1](#), [рис. 2](#) если мы отшкалируем расстояния  $r(x)$  от объектов до разделяющей гиперплоскости на  $[0, 1]$  и возьмем их в качестве уверенностей в положительном классе, то график надежности будет иметь форму сигмоиды — именно

$$\hat{p}(x) = \frac{1}{1 + e^{-(\alpha \cdot r(x) + \beta)}} \quad (13)$$

Коэффициент масштаба  $\alpha$  и сдвига  $\beta$  оптимизируются на отложенной выборке с помощью метода максимального правдоподобия. В данном методе функция деформации оказывается непрерывной и допускает много обобщений на многоклассовую задачу.

Последний линейный слой нейронной сети для объекта  $x$  выдает вектор *логитов* (**logits**):  $\mathbf{z} = (z_1, \dots, z_K)$ . Для получения оценок вероятностей классов вектор логитов пропускается через **softmax**,  $\sigma(\cdot)$ :

$$\sigma(\mathbf{z}) = \frac{1}{\sum_{j=1}^K \exp(z_j)} (\exp(z_1), \dots, \exp(z_K))$$



Калибровки Платта обобщается следующим образом [5]: для откалиброванной оценки  $a(x)$  находятся параметры масштаба и сдвига для логитов:

Вместо этого введем параметризацию  $\mathbf{W}, \mathbf{b}$ :

$$a(x) = \sigma(\mathbf{W} \cdot \mathbf{z} + \mathbf{b}) \quad (14)$$

Параметры  $\mathbf{W}$  и  $\mathbf{b}$  также оптимизируются с помощью метода максимального правдоподобия на отложенной выборке, что эквивалентно минимизации NLL ((9)). В зависимости от размерности  $\mathbf{W}$  и  $\mathbf{b}$ , можно получить разные обобщения:

1. Температурное шкалирование (**temperature scaling**):

$$\mathbf{W} = \frac{1}{T} \in \mathbb{R}, T > 0, \mathbf{b} = \mathbf{0}$$

Обобщение калибровки Платта с единственным скалярным параметром. Метод является одним из наиболее часто используемых. Увеличение температуры  $T$  приводит к увеличению неопределенности — росту энтропии выходного распределения, в то время как уменьшение, напротив, увеличивает уверенность в предсказанном классе. При этом сама классификация остается неизменной.

2. Векторное шкалирование (**vector scaling**):

$$\mathbf{W} = \text{diag}(\mathbf{v}) \in \mathbb{R}^{K \times K} \text{ — диагональная матрица, } \mathbf{v} \in \mathbb{R}^K$$

В данном подходе для каждого класса оптимизируется свой коэффициент масштаба (и сдвига, если  $\mathbf{b} \neq \mathbf{0}$  тоже оптимизируется).

3. Матричное шкалирование (**matrix scaling**):

$$\mathbf{W} \in \mathbb{R}^{K \times K}, \mathbf{b} \in \mathbb{R}^K$$

Такая параметризация является самой общей в данной группе методов и эквивалентна логистической регрессии в пространстве логитов. Тем не менее при большом числе классов модель имеет слишком много параметров и слишком сильно переобучается.

## 4.2 Калибровка на этапе обучения

Качество работы нейронных сетей сильно зависит от функции потерь, на которую они настраиваются. Чаще всего используется NLL (9). Для одного объекта  $x$  она равна кросс-энтропии между истинным вектором классификации  $\mathbf{y}$  и предсказанным распределением  $\mathbf{a}$ :

$$\text{CE}(\mathbf{y}, \mathbf{a}) = \sum_{j=1}^K y_j \log a_j \quad (15)$$

Чтобы повысить откалиброванность модели, можно модифицировать саму функцию потерь.

### 4.2.1 Сглаживание меток (Label smoothing)

В данном методе вырожденное распределение вектора классификации сглаживается в сторону равномерного. Сглаживание регулируется с помощью параметра  $\alpha \in [0, 1]$ :

$$\mathbf{y} = (y_1, \dots, y_K) \mapsto \left( (1 - \alpha)y_1 + \frac{\alpha}{K}, \dots, (1 - \alpha)y_K + \frac{\alpha}{K} \right) = \mathbf{y}' \quad (16)$$

Далее минимизируется кросс-энтропия  $\text{CE}(\mathbf{y}', \mathbf{a})$  между сглаженным вектором классификации и предсказанным распределением. Хотя использование сглаживания — не новая идея, для задачи калибровки она была предложена в [17].

### 4.2.2 Фокальная ошибка (Focal loss)




Рис. 3: Фокальная ошибка для одного объекта.  $\hat{p}$  — оценка вероятности для истинного класса

Изначально фокальная ошибка была использована для решения проблемы дисбаланса классов [18], а в задаче калибровки предложена в [19]. Для объекта, принадлежащего  $j$ -му классу, она имеет следующий вид:

$$\text{FL} = -(1 - a_j)^\gamma \cdot \log a_j, \quad \gamma \geq 0 \quad (17)$$

В случае  $\gamma = 0$  функция потерь совпадает с кросс-энтропией. С увеличением  $\gamma$ , как видим на рис. 3, уменьшается штраф за потери на объектах с уже высокой уверенностью в истинном классе. В то время как кросс-энтропия является верхней оценкой дивергенции Кульбака — Лейблера между истинным  $\mathbf{y}$  и предсказанным  $\mathbf{a}$  распределением, у фокальной ошибки из оценки вычитается энтропия предсказанного распределения  $H(\mathbf{a})$  [19]:

$$\text{CE}(\mathbf{y}, \mathbf{a}) \geq \text{KL}(\mathbf{y}||\mathbf{a}), \quad \text{FL}(\mathbf{y}, \mathbf{a}) \geq \text{KL}(\mathbf{y}||\mathbf{a}) - \gamma \cdot H(\mathbf{a}),$$

Получается, оптимизация фокальной ошибки дополнительно увеличивает энтропию предсказанного распределения, то есть помогает в борьбе с переуверенностью.

## 5 Вычислительные эксперименты

### 5.1 Дизайн экспериментов

В экспериментах были использованы следующие наборы данных:

- **CIFAR-10** [20]: Датасет содержит 60 000 цветных изображений  $32 \times 32$ , каждое относится к одному из 10 классов. Разделение на обучающую / валидационную / тестовую выборки: 50 000 / 5 000 / 5 000 изображений.
- **CIFAR-100** [20]: 60 000 цветных изображений  $32 \times 32$ , 100 классов. Обучение / валидация / тест: 50 000 / 5 000 / 5 000.
- **ImageNet 2012** [11]: Крупный датасет с изображениями, разбитыми на 1000 классов. Обучение / валидация / тест: 1.2 млн / 25 000 / 25 000
- **Tiny ImageNet** [11]: 110 000 изображений  $64 \times 64$ , разделенных на 200 классов. Является подмножеством предыдущего датасета. Обучение / валидация / тест: 100 000 / 5 000 / 5 000.

Для вычислений использовались предобученные нейронные сети с различными архитектурами из открытых репозиторий. В экспериментах модели и датасеты разбиты на две основные группы:

1. К первой группе отнесены нейронные сети, обученные на CIFAR-10, CIFAR-100, ImageNet. Веса для моделей были взяты соответственно из репозиторий [21, 22, 23]. Модели данной группы используются для сравнения методов калибровки, основанных на постобработке.
2. Ко второй группе отнесены предобученные нейросети из репозитория [24]. Здесь использованы датасеты CIFAR-10, CIFAR-100 и Tiny ImageNet. Данные нейросети были обучены для статьи [19] — для части из них использовалась фокальная ошибка и сглаживание меток.

При обучении модели настраивались на данные из обучающей выборки (или ее части), калибровались на отложенной выборке. Все построенные диаграммы надежности и метрики соответствуют тестовой выборке.

Все эксперименты, реализация методов калибровки и оценок были выполнены на языке Python. Температурное, векторное и матричное шкалирование настраивались на GPU и были реализованы с использованием библиотеки PyTorch, остальные методы и метрики реализованы с использованием библиотек SciPy и sklearn. В гистограммном биннинге использовалось 20 бинов; ECE, swECE и MCE считались для 15 бинов.

## 5.2 Результаты

Полные таблицы с измерениями приведены в [приложении](#) к работе, диаграммы надежности для всех рассмотренных моделей можно найти в репозитории [\[25\]](#).

Рассмотрим диаграммы надежности для ShuffleNetV2 (CIFAR-100, [рис. 4](#)): можно видеть «типичное» состояние откалиброванности нейросети — переуверенность. Калибровка помогает исправить ситуацию: в данном случае лучше с точки зрения всех метрик лучше всего сработало температурное шкалирование. Гистограммный биннинг работает слишком агрессивно для большого числа классов: в бинах часто оказывается мало объектов.




Рис. 4

Для малого числа классов, напротив, гистограммный биннинг работает лучше всего с точки зрения уверенности в предсказании ([табл. 5](#), [табл. 6](#) — почти для всех моделей на CIFAR-10). Но отметим, что нейронные сети уже с очень высоким качеством решают такую задачу классификации. Почти все уверенности в предсказании близки к 1, как, например, на [рис. 5](#). И точки зрения MSE ([табл. 9](#), [табл. 10](#)) — метрике, в которой не учитываются «веса» бинов, гистограммный биннинг дает низкое качество откалиброванности.

Для матричного шкалирования мы не приводим диаграммы надежности: метод чересчур склонен к переобучению при большом числе классов. В итоге матричное

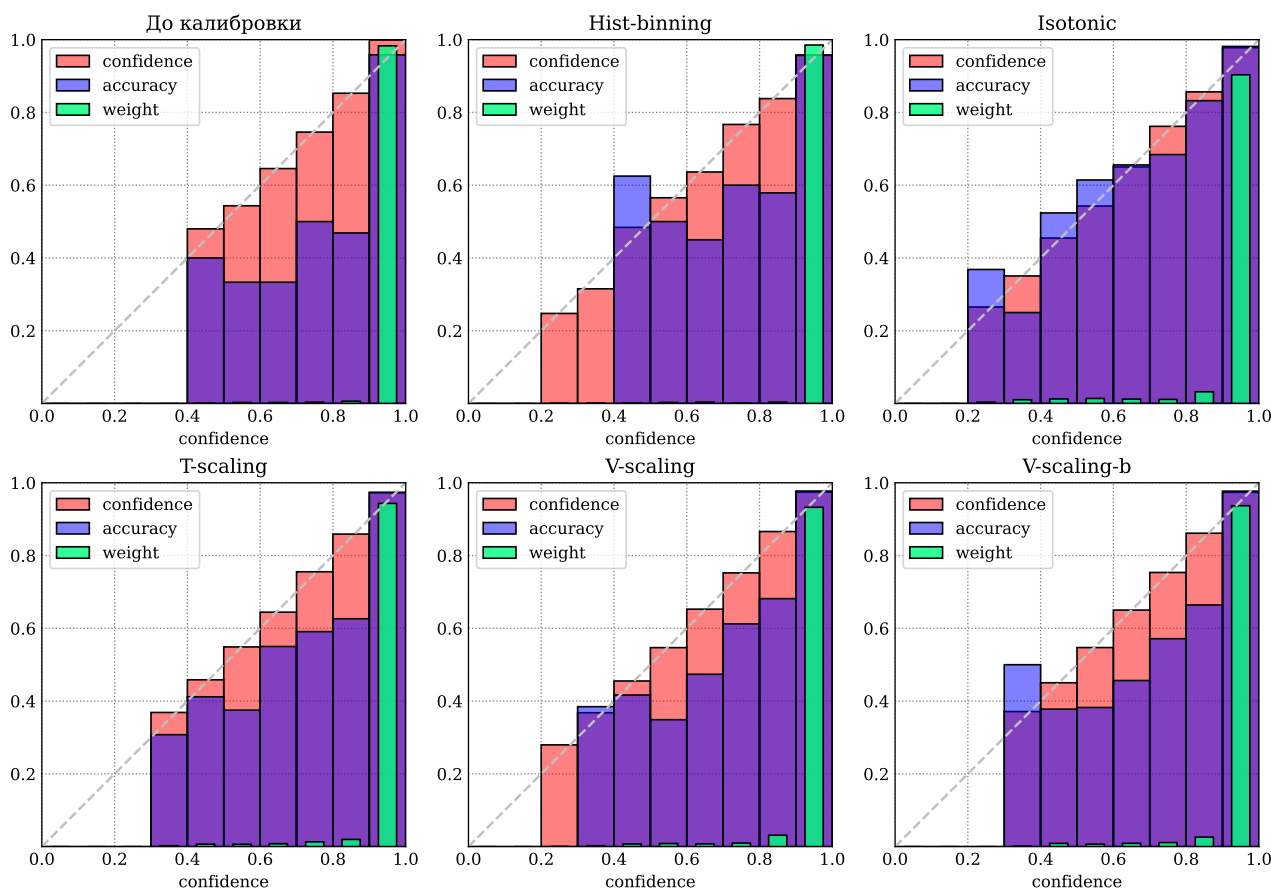


Рис. 5

шкалирование существенно ухудшает качество классификации (табл. 3, табл. 3) для всех датасетов, кроме, опять же, малоклассового CIFAR-10.

Одним из наиболее часто применяемых методов калибровки нейросетей является температурное шкалирование. Метод действительно не оказывает влияния на классификацию, в то время как другие варианты калибровки часто уменьшают точность (табл. 3, табл. 4).

С точки зрения NLL ожидаемо лучшими оказались температурное и векторное шкалирование (ведь в процессе калибровки именно данная ошибки и оптимизировалась) — табл. 11, табл. 12. Для Brier Score лучшим методом калибровки во многих случаях становилась изотоническая регрессия — табл. 13, табл. 14.

Фокальная ошибка и сглаживание меток действительно действительно дают более откалиброванные модели, чем при настройке на стандартную кросс-энтропию — как с точки зрения уверенности в предсказанном классе (табл. 1), так и с точки зрения поклассовых оценок (табл. 2). При этом далее модели можно калибровать с помощью постобработки. В оригинальной работе [19] для калибровки моделей, обученных на фокальную ошибку, использовалось только температурное шкалирование. Хотя относительно ECE (табл. 6) такой подход действительно действительно показывает высокие результаты, с точки зрения поклассовой  $swECE$  (табл. 8) чаще лучше работает векторное шкалирование. Для моделей первой группы (табл. 7) векторное шкалирование тоже в основном минимизи-

рует  $\text{swECE}$ . Такие результаты вполне ожидаемы, поскольку векторное шкалирование находит отдельные коэффициенты деформации для каждого класса.

Датасет	Модель	CE	FL 1	FL 2	FL 3	LS 0.05
CIFAR-10	DenseNet121	4.53	3.47	2.02	1.68	<b>1.65</b>
CIFAR-10	ResNet110	4.73	3.70	2.78	<b>1.61</b>	2.20
CIFAR-10	ResNet50	4.26	3.88	2.55	<b>1.58</b>	3.07
CIFAR-10	Wide-ResNet-26-10	3.25	2.66	<b>1.57</b>	1.98	4.33
CIFAR-100	DenseNet121	20.90	14.54	8.40	<b>4.49</b>	13.27
CIFAR-100	ResNet110	19.76	15.35	12.10	<b>9.22</b>	11.44
CIFAR-100	ResNet50	18.14	13.36	8.60	<b>4.99</b>	8.15
CIFAR-100	Wide-ResNet-26-10	16.28	9.12	4.22	<b>2.20</b>	5.27
TinyImageNet	ResNet50	15.98	7.87	3.32	<b>1.93</b>	15.73

Датасет	Модель	CE	FL 1	FL 2	FL 3	LS 0.05
CIFAR-10	DenseNet121	0.948	0.755	<b>0.514</b>	0.524	0.576
CIFAR-10	ResNet110	0.990	0.804	0.660	<b>0.505</b>	0.673
CIFAR-10	ResNet50	0.941	0.836	0.625	<b>0.524</b>	0.766
CIFAR-10	Wide-ResNet-26-10	0.699	0.611	<b>0.479</b>	0.523	0.869
CIFAR-100	DenseNet121	0.458	0.364	0.280	<b>0.254</b>	0.315
CIFAR-100	ResNet110	0.433	0.372	0.321	<b>0.281</b>	0.299
CIFAR-100	ResNet50	0.412	0.337	0.282	<b>0.256</b>	0.271
CIFAR-100	Wide-ResNet-26-10	0.372	0.264	<b>0.218</b>	0.226	0.239
TinyImageNet	ResNet50	0.250	0.218	0.205	<b>0.203</b>	0.231

Таблица 1: ECE, % – Expected Calibration Error, (меньше – лучше), 15 бинов без постобработки, столбцы соответствуют разным функциям потерь

Таблица 2:  $\text{swECE}$ , % – Classwise Expected Calibration Error (меньше – лучше), 15 бинов без постобработки, столбцы соответствуют разным функциям потерь

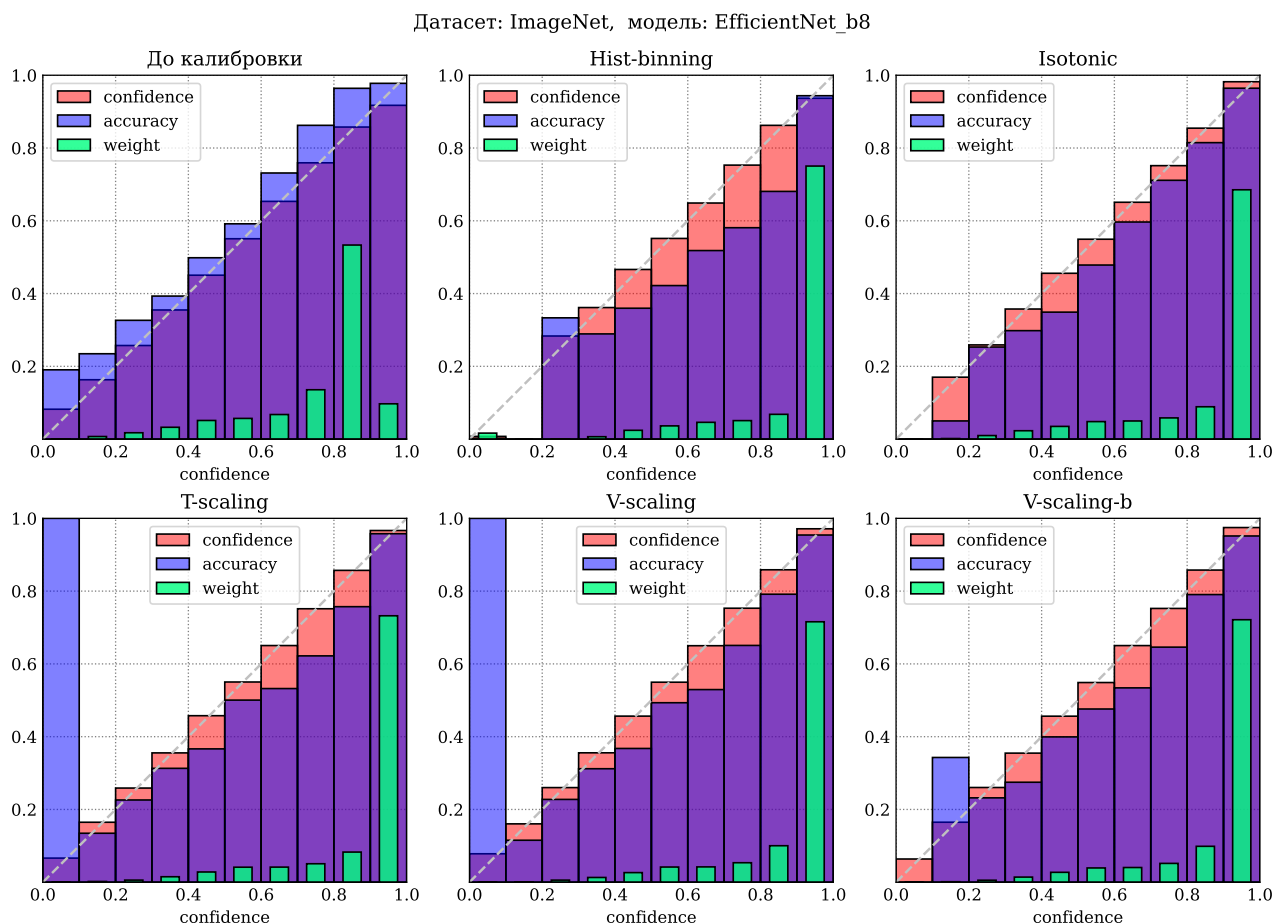


Рис. 6

Рассмотрим также диаграммы калибровки для EfficientNet (рис. 6). Среди всех использованных моделей, у данной нейросети четче всего видна недоуверенность — большая часть оценок сосредоточена не на  $[0.9, 1]$ , а на  $[0.8, 0.9]$ . Причина такого поведения может быть как раз в особенности обучения: модель обучалась со сглаживанием

меток ( $\alpha = 0.1$ ) [23]. Все методы калибровки привели к заметному повышению уверенности.

## 6 Заключение

Таким образом, в данной работе мы сравнили основные методы калибровки, эксперименты были проведены для различных архитектур сверточных нейросетей. Применимость того или иного алгоритма калибровки существенно зависит от количества данных и выбранного критерия качества. Методы, строящие отдельные функции деформации для каждого класса, показывают высокое качество только при достаточном размере отложенной выборке (соответственно, небольшом числе классов). Стратегии, в основе которых лежит линейное преобразование логитов (например, температурное шкалирование) лучше работают для задач с большим числом классов, но сильно переобучаются при чрезмерной параметризации (матричное шкалирование). Калибровка уверенности до сих пор остается открытой проблемой, и даже способ оценки откалиброванности модели не является решенным вопросом.



## Список литературы

- [1] Syed Muhammad Anwar et al. “Medical image analysis using convolutional neural networks: a review”. In: *Journal of medical systems* 42.11 (2018), pp. 1–13.
- [2] Sorin Grigorescu et al. “A survey of deep learning techniques for autonomous driving”. In: *Journal of Field Robotics* 37.3 (2020), pp. 362–386.
- [3] Yonghui Wu et al. “Google’s neural machine translation system: Bridging the gap between human and machine translation”. In: *arXiv preprint arXiv:1609.08144* (2016).
- [4] Yoshua Bengio et al. “A neural probabilistic language model”. In: *The journal of machine learning research* 3 (2003), pp. 1137–1155.
- [5] Chuan Guo et al. “On Calibration of Modern Neural Networks”. In: *ICML 2017*. Vol. 70. Proceedings of Machine Learning Research. PMLR, 2017, pp. 1321–1330.
- [6] Alexandru Niculescu-Mizil and Rich Caruana. “Predicting good probabilities with supervised learning”. In: Jan. 2005, pp. 625–632. DOI: [10.1145/1102351.1102430](https://doi.org/10.1145/1102351.1102430).
- [7] Rich Caruana and Alexandru Niculescu-Mizil. “An Empirical Comparison of Supervised Learning Algorithms”. In: *Proceedings of the 23rd International Conference on Machine Learning*. ICML ’06. Pittsburgh, Pennsylvania, USA: Association for Computing Machinery, 2006, pp. 161–168. ISBN: 1595933832. DOI: [10.1145/1143844.1143865](https://doi.org/10.1145/1143844.1143865).
- [8] Bianca Zadrozny and Charles Elkan. “Transforming Classifier Scores into Accurate Multiclass Probability Estimates”. In: *Proceedings of the Eighth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. KDD ’02. Edmonton, Alberta, Canada: Association for Computing Machinery, 2002, pp. 694–699. ISBN: 158113567X. DOI: [10.1145/775047.775151](https://doi.org/10.1145/775047.775151).
- [9] “The Comparison and Evaluation of Forecasters”. In: *Journal of the Royal Statistical Society. Series D (The Statistician)* 32.1/2 (1983), pp. 12–22. ISSN: 00390526, 14679884.
- [10] Meelis Kull et al. “Beyond temperature scaling: Obtaining well-calibrated multi-class probabilities with Dirichlet calibration”. In: *Advances in Neural Information Processing Systems*. Ed. by H. Wallach et al. Vol. 32. Curran Associates, Inc., 2019.
- [11] Jia Deng et al. “Imagenet: A large-scale hierarchical image database”. In: *2009 IEEE conference on computer vision and pattern recognition*. Ieee. 2009, pp. 248–255.
- [12] Mahdi Pakdaman Naeini, Gregory F Cooper, and Milos Hauskrecht. “Obtaining Well Calibrated Probabilities Using Bayesian Binning.” In: *AAAI*. 2015, 2901–2907.
- [13] Jeremy Nixon et al. *Measuring Calibration in Deep Learning*. 2020. arXiv: [1904.01685](https://arxiv.org/abs/1904.01685) [cs.LG].
- [14] Ananya Kumar, Percy Liang, and Tengyu Ma. “Verified Uncertainty Calibration”. In: *NeurIPS 2019*. 2019, pp. 3787–3798.



- [15] Bianca Zadrozny and Charles Elkan. “Obtaining Calibrated Probability Estimates from Decision Trees and Naive Bayesian Classifiers”. In: *Proceedings of the Eighteenth International Conference on Machine Learning*. ICML ’01. San Francisco, CA, USA: Morgan Kaufmann Publishers Inc., 2001, pp. 609–616. ISBN: 1558607781.
- [16] John C. Platt. “Probabilistic Outputs for Support Vector Machines and Comparisons to Regularized Likelihood Methods”. In: *ADVANCES IN LARGE MARGIN CLASSIFIERS*. MIT Press, 1999, pp. 61–74.
- [17] Rafael Müller, Simon Kornblith, and Geoffrey E Hinton. “When does label smoothing help?” In: *Advances in Neural Information Processing Systems*. Curran Associates, Inc., 2019.
- [18] Tsung-Yi Lin et al. “Focal Loss for Dense Object Detection”. In: *2017 IEEE International Conference on Computer Vision (ICCV)*. 2017, pp. 2999–3007. DOI: [10.1109/ICCV.2017.324](https://doi.org/10.1109/ICCV.2017.324).
- [19] Jishnu Mukhoti et al. “Calibrating Deep Neural Networks using Focal Loss”. In: (2020).
- [20] A. Krizhevsky and G. Hinton. “Learning multiple layers of features from tiny images”. In: *Master’s thesis, Department of Computer Science, University of Toronto* (2009).
- [21] Huy Phan. *huyvnphan/PyTorch\_CIFAR10*. Version v3.0.1. Jan. 2021. DOI: [10.5281/zenodo.4431043](https://doi.org/10.5281/zenodo.4431043). URL: <https://doi.org/10.5281/zenodo.4431043>.
- [22] chenyaof. *PyTorch CIFAR models*. 2021. URL: <https://github.com/chenyaof/pytorch-cifar-models>.
- [23] Ross Wightman. *PyTorch Image Models*. <https://github.com/rwightman/pytorch-image-models>. 2019. DOI: [10.5281/zenodo.4414861](https://doi.org/10.5281/zenodo.4414861).
- [24] URL: [https://github.com/torrvision/focal\\_calibration](https://github.com/torrvision/focal_calibration).
- [25] URL: <https://github.com/artnitolog/diary>.

# Приложения

## А Качество классификации моделей

Датасет	Модель	До калибровки	Hist-binning	Isotonic	T-scaling	V-scaling	V-scaling-b	M-scaling-b
CIFAR-10	DenseNet121	<b>93.92</b>	93.52	93.72	<b>93.92</b>	93.84	93.80	93.80
CIFAR-10	DenseNet161	93.70	<b>93.74</b>	93.58	93.70	93.72	<b>93.74</b>	93.52
CIFAR-10	DenseNet169	<b>94.08</b>	93.44	93.84	<b>94.08</b>	94.02	93.94	93.78
CIFAR-10	GoogleNet	<b>92.92</b>	92.58	92.68	<b>92.92</b>	92.90	92.84	92.76
CIFAR-10	InceptionV3	<b>93.32</b>	93.12	93.28	<b>93.32</b>	93.22	<b>93.32</b>	93.26
CIFAR-10	MobileNetV2	<b>93.42</b>	93.40	<b>93.42</b>	<b>93.42</b>	93.26	93.36	93.36
CIFAR-10	ResNet18	<b>92.54</b>	92.14	92.34	<b>92.54</b>	92.48	92.40	92.18
CIFAR-10	ResNet34	<b>93.24</b>	92.74	92.92	<b>93.24</b>	93.14	93.16	92.94
CIFAR-10	ResNet50	<b>93.44</b>	93.10	93.22	<b>93.44</b>	93.40	93.38	93.24
CIFAR-10	VGG11_bn	91.96	91.66	91.84	91.96	91.86	91.80	<b>91.98</b>
CIFAR-10	VGG13_bn	93.86	93.40	93.74	93.86	<b>93.92</b>	93.82	93.68
CIFAR-10	VGG16_bn	<b>93.52</b>	93.38	93.42	<b>93.52</b>	93.36	93.36	93.36
CIFAR-10	VGG19_bn	93.76	93.36	93.62	93.76	93.70	<b>93.84</b>	93.56
CIFAR-100	MobileNetV2_x0_5	<b>70.32</b>	67.56	69.86	<b>70.32</b>	70.26	69.94	55.38
CIFAR-100	MobileNetV2_x1_0	73.34	70.74	72.98	73.34	73.20	<b>73.50</b>	59.24
CIFAR-100	MobileNetV2_x1_4	<b>76.22</b>	72.96	75.58	<b>76.22</b>	75.72	75.80	63.10
CIFAR-100	ResNet20	<b>67.80</b>	63.80	66.72	<b>67.80</b>	67.36	67.54	49.94
CIFAR-100	ResNet32	<b>69.10</b>	65.90	68.64	<b>69.10</b>	68.90	68.70	52.20
CIFAR-100	ResNet44	<b>70.82</b>	67.86	70.22	<b>70.82</b>	70.42	70.56	55.16
CIFAR-100	ResNet56	<b>72.04</b>	69.54	71.62	<b>72.04</b>	71.72	71.58	56.34
CIFAR-100	ShuffleNetV2_x0_5	66.86	64.22	66.68	66.86	<b>66.98</b>	66.58	50.02
CIFAR-100	ShuffleNetV2_x1_0	<b>71.58</b>	69.16	71.24	<b>71.58</b>	71.26	71.30	57.50
CIFAR-100	ShuffleNetV2_x1_5	73.60	70.90	73.34	73.60	73.72	<b>73.80</b>	61.30
CIFAR-100	ShuffleNetV2_x2_0	<b>74.92</b>	72.30	74.44	<b>74.92</b>	74.84	74.82	63.04
CIFAR-100	VGG11_bn	<b>69.96</b>	67.76	69.34	<b>69.96</b>	69.56	69.58	59.90
CIFAR-100	VGG13_bn	<b>73.90</b>	71.84	73.02	<b>73.90</b>	73.56	73.36	62.58
CIFAR-100	VGG16_bn	<b>73.30</b>	71.34	72.78	<b>73.30</b>	72.96	72.94	64.28
CIFAR-100	VGG19_bn	<b>73.14</b>	71.78	72.76	<b>73.14</b>	73.00	72.82	63.78
ImageNet	EfficientNet_b8	85.52	83.43	84.92	85.52	<b>85.54</b>	85.47	79.12
ImageNet	MobileNetV2_120d	<b>77.68</b>	73.57	76.79	<b>77.68</b>	77.36	77.16	59.84
ImageNet	RepVGG_b3	<b>80.57</b>	77.68	79.89	<b>80.57</b>	80.22	80.17	66.38
ImageNet	VGG19_bn	<b>74.35</b>	70.47	73.72	<b>74.35</b>	73.92	73.62	54.06

Таблица 3: Ассурасу, % (больше – лучше) – доля правильных ответов группа 1

Датасет	Модель	До калибровки	Hist-binning	Isotonic	T-scaling	V-scaling	V-scaling-b	M-scaling-b
CIFAR-10	DenseNet121 (CE)	94.92	<b>94.98</b>	94.84	94.92	94.94	94.96	94.76
CIFAR-10	DenseNet121 (FL 1)	94.84	94.68	94.82	94.84	95.00	<b>95.02</b>	94.52
CIFAR-10	DenseNet121 (FL 2)	94.90	94.60	<b>94.96</b>	94.90	94.84	94.80	94.80
CIFAR-10	DenseNet121 (FL 3)	94.24	94.24	94.20	94.24	94.34	94.24	<b>94.36</b>
CIFAR-10	DenseNet121 (LS 0.05)	94.52	94.62	<b>94.66</b>	94.52	94.56	94.58	94.62
CIFAR-10	ResNet110 (CE)	94.82	94.70	94.76	94.82	94.84	94.86	<b>94.90</b>
CIFAR-10	ResNet110 (FL 1)	94.80	94.90	94.84	94.80	94.86	<b>95.00</b>	94.98
CIFAR-10	ResNet110 (FL 2)	94.82	94.82	<b>94.96</b>	94.82	<b>94.96</b>	94.90	94.84
CIFAR-10	ResNet110 (FL 3)	94.70	94.64	94.84	94.70	94.84	<b>94.86</b>	94.70
CIFAR-10	ResNet110 (LS 0.05)	94.36	94.36	<b>94.48</b>	94.36	94.32	94.32	94.40
CIFAR-10	ResNet50 (CE)	<b>95.02</b>	94.62	94.66	<b>95.02</b>	95.00	94.96	94.82
CIFAR-10	ResNet50 (FL 1)	94.58	94.34	94.52	94.58	<b>94.60</b>	94.52	94.58
CIFAR-10	ResNet50 (FL 2)	94.80	94.62	94.82	94.80	<b>94.90</b>	<b>94.90</b>	94.88
CIFAR-10	ResNet50 (FL 3)	94.52	94.48	<b>94.66</b>	94.52	94.58	94.60	94.44
CIFAR-10	ResNet50 (LS 0.05)	94.26	94.02	94.18	94.26	94.26	94.16	<b>94.30</b>
CIFAR-10	Wide-ResNet-26-10 (CE)	96.12	96.02	96.08	96.12	<b>96.20</b>	<b>96.20</b>	96.10
CIFAR-10	Wide-ResNet-26-10 (FL 1)	<b>95.70</b>	95.26	95.56	<b>95.70</b>	95.64	95.66	<b>95.70</b>
CIFAR-10	Wide-ResNet-26-10 (FL 2)	<b>95.56</b>	95.06	95.50	<b>95.56</b>	95.40	95.46	95.48
CIFAR-10	Wide-ResNet-26-10 (FL 3)	95.64	95.62	<b>95.80</b>	95.64	95.74	95.74	95.64
CIFAR-10	Wide-ResNet-26-10 (LS 0.05)	95.66	95.50	95.40	95.66	95.64	<b>95.68</b>	95.42
CIFAR-100	DenseNet121 (CE)	75.32	74.52	75.26	75.32	<b>75.76</b>	75.70	65.60
CIFAR-100	DenseNet121 (FL 1)	75.66	74.12	75.90	75.66	<b>76.02</b>	76.00	65.24
CIFAR-100	DenseNet121 (FL 2)	75.90	73.50	<b>76.22</b>	75.90	75.90	76.02	65.32
CIFAR-100	DenseNet121 (FL 3)	76.10	72.90	75.86	76.10	76.16	<b>76.20</b>	65.06
CIFAR-100	DenseNet121 (LS 0.05)	75.54	74.56	75.66	75.54	75.66	<b>75.74</b>	66.60
CIFAR-100	ResNet110 (CE)	76.44	76.02	76.50	76.44	76.80	<b>76.88</b>	66.20
CIFAR-100	ResNet110 (FL 1)	76.84	75.28	76.48	76.84	<b>77.34</b>	77.28	66.52
CIFAR-100	ResNet110 (FL 2)	76.74	74.48	76.68	76.74	<b>77.04</b>	76.90	67.00
CIFAR-100	ResNet110 (FL 3)	76.30	74.80	76.56	76.30	76.66	<b>76.82</b>	66.46
CIFAR-100	ResNet110 (LS 0.05)	75.96	74.48	75.68	75.96	76.10	<b>76.18</b>	66.66
CIFAR-100	ResNet50 (CE)	76.00	74.48	75.62	76.00	76.12	<b>76.14</b>	65.86
CIFAR-100	ResNet50 (FL 1)	76.38	74.22	76.36	76.38	<b>76.66</b>	76.46	66.32
CIFAR-100	ResNet50 (FL 2)	<b>76.58</b>	73.90	76.10	<b>76.58</b>	76.52	76.46	65.40
CIFAR-100	ResNet50 (FL 3)	<b>77.08</b>	74.44	76.42	<b>77.08</b>	76.86	76.94	64.62
CIFAR-100	ResNet50 (LS 0.05)	76.18	74.38	76.24	76.18	76.42	<b>76.48</b>	67.98
CIFAR-100	Wide-ResNet-26-10 (CE)	78.26	77.22	77.98	78.26	<b>78.38</b>	78.22	67.72
CIFAR-100	Wide-ResNet-26-10 (FL 1)	<b>79.84</b>	78.10	79.80	<b>79.84</b>	79.76	79.76	68.82
CIFAR-100	Wide-ResNet-26-10 (FL 2)	79.64	77.54	79.64	79.64	79.96	<b>80.04</b>	69.44
CIFAR-100	Wide-ResNet-26-10 (FL 3)	79.70	76.96	79.62	79.70	<b>79.86</b>	79.80	70.18
CIFAR-100	Wide-ResNet-26-10 (LS 0.05)	78.14	75.98	77.90	78.14	<b>78.26</b>	78.24	69.62
TinyImageNet	ResNet50 (CE)	<b>49.98</b>	44.92	49.10	<b>49.98</b>	49.44	49.24	32.66
TinyImageNet	ResNet50 (FL 1)	<b>50.10</b>	44.96	49.48	<b>50.10</b>	50.04	49.94	31.32
TinyImageNet	ResNet50 (FL 2)	<b>51.86</b>	46.56	51.14	<b>51.86</b>	51.82	51.62	31.96
TinyImageNet	ResNet50 (FL 3)	<b>51.06</b>	44.56	50.18	<b>51.06</b>	50.82	50.94	32.08
TinyImageNet	ResNet50 (LS 0.05)	<b>53.62</b>	47.18	51.94	<b>53.62</b>	52.84	52.78	36.82

Таблица 4: Ассурасу, % (больше – лучше) – доля правильных ответов группа 2

## В Биннинговые метрики

Датасет	Модель	До калибровки	Hist-binning	Isotonic	T-scaling	V-scaling	V-scaling-b	M-scaling-b
CIFAR-10	DenseNet121	1.86	<b>1.08</b>	2.10	1.64	1.67	1.58	1.49
CIFAR-10	DenseNet161	2.11	<b>1.08</b>	1.64	1.68	1.87	1.75	1.75
CIFAR-10	DenseNet169	2.04	<b>1.42</b>	1.87	1.72	1.64	1.62	1.64
CIFAR-10	GoogleNet	1.65	<b>0.89</b>	1.36	1.21	1.46	1.37	1.34
CIFAR-10	InceptionV3	2.06	<b>1.35</b>	1.91	1.88	1.99	1.91	1.86
CIFAR-10	MobileNetV2	2.92	<b>1.45</b>	1.74	1.87	2.09	1.95	1.78
CIFAR-10	ResNet18	2.51	<b>1.60</b>	2.03	2.13	1.98	1.93	2.16
CIFAR-10	ResNet34	2.67	<b>1.44</b>	2.09	1.96	1.70	1.88	1.75
CIFAR-10	ResNet50	2.50	<b>1.06</b>	1.70	1.67	1.72	1.59	1.62
CIFAR-10	VGG11_bn	1.87	2.21	<b>1.65</b>	1.83	1.88	1.90	1.76
CIFAR-10	VGG13_bn	<b>1.41</b>	1.42	1.54	1.44	1.44	1.43	1.72
CIFAR-10	VGG16_bn	1.86	<b>1.08</b>	1.61	1.71	1.93	1.81	1.74
CIFAR-10	VGG19_bn	2.15	<b>1.02</b>	1.34	1.87	2.00	1.98	2.14
CIFAR-100	MobileNetV2_x0_5	12.69	9.39	5.86	<b>3.28</b>	3.31	3.57	44.57
CIFAR-100	MobileNetV2_x1_0	11.77	10.13	6.02	3.78	<b>3.46</b>	3.69	40.68
CIFAR-100	MobileNetV2_x1_4	9.66	10.13	4.29	2.90	<b>2.69</b>	2.86	36.79
CIFAR-100	ResNet20	11.21	9.01	5.79	<b>2.48</b>	3.11	3.13	50.05
CIFAR-100	ResNet32	13.95	10.34	5.47	2.61	<b>2.28</b>	2.77	47.79
CIFAR-100	ResNet44	14.99	8.42	6.42	<b>3.18</b>	3.49	3.48	44.84
CIFAR-100	ResNet56	14.72	7.86	5.68	3.13	<b>3.10</b>	3.40	43.65
CIFAR-100	ShuffleNetV2_x0_5	12.93	9.62	5.38	<b>2.22</b>	2.38	2.80	49.77
CIFAR-100	ShuffleNetV2_x1_0	11.68	8.15	5.90	<b>3.68</b>	4.24	4.18	42.32
CIFAR-100	ShuffleNetV2_x1_5	9.86	8.94	5.44	<b>4.56</b>	4.88	4.64	38.44
CIFAR-100	ShuffleNetV2_x2_0	7.68	10.14	4.91	<b>4.26</b>	4.78	4.78	36.80
CIFAR-100	VGG11_bn	15.86	10.61	7.78	<b>5.17</b>	5.80	6.08	29.38
CIFAR-100	VGG13_bn	14.06	8.12	7.19	5.84	<b>5.80</b>	5.84	27.53
CIFAR-100	VGG16_bn	19.33	8.87	5.74	4.18	<b>3.93</b>	4.03	28.60
CIFAR-100	VGG19_bn	20.17	8.79	5.22	4.53	3.74	<b>3.61</b>	31.98
ImageNet	EfficientNet_b8	8.98	4.88	<b>2.96</b>	3.17	3.51	3.95	20.15
ImageNet	MobileNetV2_120d	6.85	7.02	1.96	<b>1.61</b>	2.11	2.90	38.18
ImageNet	RepVGG_b3	<b>3.23</b>	6.17	3.61	3.95	4.08	4.76	32.42
ImageNet	VGG19_bn	3.69	9.26	3.93	1.92	<b>1.53</b>	2.16	44.68

Таблица 5: ECE, % – Expected Calibration Error, (меньше – лучше), 15 бинов группа 1

Датасет	Модель	До калибровки	Hist-binning	Isotonic	T-scaling	V-scaling	V-scaling-b	M-scaling-b
CIFAR-10	DenseNet121 (CE)	4.53	<b>0.38</b>	1.24	1.64	1.19	1.29	1.45
CIFAR-10	DenseNet121 (FL 1)	3.47	0.87	<b>0.65</b>	1.26	0.88	1.05	1.44
CIFAR-10	DenseNet121 (FL 2)	2.02	0.97	<b>0.73</b>	0.95	1.08	1.01	1.18
CIFAR-10	DenseNet121 (FL 3)	1.68	<b>1.17</b>	1.32	1.49	1.32	1.38	1.84
CIFAR-10	DenseNet121 (LS 0.05)	1.65	<b>0.93</b>	1.55	1.22	1.28	1.24	1.29
CIFAR-10	ResNet110 (CE)	4.73	<b>1.01</b>	1.11	1.23	1.36	1.39	1.25
CIFAR-10	ResNet110 (FL 1)	3.70	<b>0.71</b>	0.99	1.11	1.20	1.06	1.05
CIFAR-10	ResNet110 (FL 2)	2.78	<b>0.55</b>	1.20	1.03	0.94	0.96	1.07
CIFAR-10	ResNet110 (FL 3)	1.61	<b>0.84</b>	0.96	1.24	0.94	0.84	1.01
CIFAR-10	ResNet110 (LS 0.05)	2.20	1.77	0.90	1.56	1.07	0.88	<b>0.72</b>
CIFAR-10	ResNet50 (CE)	4.26	<b>0.70</b>	0.96	1.41	1.17	1.10	1.23
CIFAR-10	ResNet50 (FL 1)	3.88	1.88	<b>1.46</b>	1.58	1.65	1.67	1.85
CIFAR-10	ResNet50 (FL 2)	2.55	<b>1.08</b>	1.09	1.17	1.52	1.52	1.14
CIFAR-10	ResNet50 (FL 3)	1.58	<b>0.78</b>	0.98	1.11	1.16	1.01	1.56
CIFAR-10	ResNet50 (LS 0.05)	3.07	1.23	<b>1.14</b>	1.35	1.35	1.43	1.40
CIFAR-10	Wide-ResNet-26-10 (CE)	3.25	0.60	<b>0.50</b>	1.07	0.84	0.91	0.90
CIFAR-10	Wide-ResNet-26-10 (FL 1)	2.66	0.95	1.03	<b>0.87</b>	1.08	1.17	1.05
CIFAR-10	Wide-ResNet-26-10 (FL 2)	1.57	1.40	<b>1.12</b>	1.18	1.37	1.31	1.42
CIFAR-10	Wide-ResNet-26-10 (FL 3)	1.98	<b>0.82</b>	0.89	1.06	1.08	0.86	0.89
CIFAR-10	Wide-ResNet-26-10 (LS 0.05)	4.33	<b>0.72</b>	0.94	0.99	1.17	1.17	1.23
CIFAR-100	DenseNet121 (CE)	20.90	7.00	6.18	4.82	4.74	<b>4.72</b>	34.38
CIFAR-100	DenseNet121 (FL 1)	14.54	6.03	7.31	<b>5.18</b>	5.22	5.38	34.71
CIFAR-100	DenseNet121 (FL 2)	8.40	10.42	4.47	<b>4.16</b>	4.37	4.42	34.63
CIFAR-100	DenseNet121 (FL 3)	4.49	9.10	4.16	<b>3.98</b>	4.55	4.45	34.84
CIFAR-100	DenseNet121 (LS 0.05)	13.27	6.98	7.03	7.44	<b>3.32</b>	3.49	33.31
CIFAR-100	ResNet110 (CE)	19.76	<b>3.99</b>	6.09	5.63	5.37	5.44	33.74
CIFAR-100	ResNet110 (FL 1)	15.35	6.16	6.56	4.87	<b>4.83</b>	4.84	33.41
CIFAR-100	ResNet110 (FL 2)	12.10	8.50	5.92	<b>5.48</b>	5.51	5.61	32.91
CIFAR-100	ResNet110 (FL 3)	9.22	8.68	<b>4.67</b>	5.36	5.41	5.39	33.53
CIFAR-100	ResNet110 (LS 0.05)	11.44	6.95	5.86	<b>4.41</b>	4.50	4.66	33.25
CIFAR-100	ResNet50 (CE)	18.14	<b>4.75</b>	7.24	6.02	6.52	6.53	34.07
CIFAR-100	ResNet50 (FL 1)	13.36	5.81	7.06	<b>5.29</b>	5.44	5.61	33.62
CIFAR-100	ResNet50 (FL 2)	8.60	9.41	4.90	<b>4.72</b>	4.91	4.90	34.52
CIFAR-100	ResNet50 (FL 3)	4.99	7.73	4.07	<b>3.39</b>	3.83	3.98	35.30
CIFAR-100	ResNet50 (LS 0.05)	8.15	7.68	6.61	<b>5.27</b>	5.32	5.32	31.94
CIFAR-100	Wide-ResNet-26-10 (CE)	16.28	4.91	6.43	<b>4.79</b>	5.21	5.00	32.23
CIFAR-100	Wide-ResNet-26-10 (FL 1)	9.12	8.12	5.40	4.31	4.35	<b>4.24</b>	31.16
CIFAR-100	Wide-ResNet-26-10 (FL 2)	4.22	7.61	<b>3.47</b>	3.87	4.01	3.75	30.53
CIFAR-100	Wide-ResNet-26-10 (FL 3)	<b>2.20</b>	8.05	3.33	3.62	3.62	3.79	29.80
CIFAR-100	Wide-ResNet-26-10 (LS 0.05)	5.27	7.52	5.36	<b>4.78</b>	4.85	4.83	30.37
TinyImageNet	ResNet50 (CE)	15.98	9.96	10.06	<b>6.67</b>	7.26	7.83	65.77
TinyImageNet	ResNet50 (FL 1)	7.87	9.96	6.12	<b>4.17</b>	4.76	5.54	67.23
TinyImageNet	ResNet50 (FL 2)	3.32	9.49	4.94	<b>2.98</b>	3.63	3.82	66.81
TinyImageNet	ResNet50 (FL 3)	1.93	9.88	3.13	<b>1.77</b>	2.61	2.70	66.65
TinyImageNet	ResNet50 (LS 0.05)	15.73	6.29	<b>3.02</b>	7.02	7.18	7.56	60.64

Таблица 6: ECE, % – Expected Calibration Error, (меньше – лучше), 15 бинов группа 2

Датасет	Модель	До калибровки	Hist-binning	Isotonic	T-scaling	V-scaling	V-scaling-b	M-scaling-b
CIFAR-10	DenseNet121	0.513	0.509	0.566	0.514	0.548	0.491	<b>0.483</b>
CIFAR-10	DenseNet161	0.646	0.536	0.534	0.629	0.531	<b>0.527</b>	0.536
CIFAR-10	DenseNet169	0.551	0.566	0.527	0.536	<b>0.485</b>	0.490	0.518
CIFAR-10	GoogleNet	0.641	0.579	0.543	0.559	0.544	<b>0.520</b>	0.545
CIFAR-10	InceptionV3	0.596	0.573	<b>0.543</b>	0.598	0.543	0.573	0.553
CIFAR-10	MobileNetV2	0.638	<b>0.500</b>	0.502	0.543	0.572	0.574	0.546
CIFAR-10	ResNet18	0.649	0.578	0.570	0.634	0.590	<b>0.538</b>	0.581
CIFAR-10	ResNet34	0.714	<b>0.549</b>	0.549	0.671	0.584	0.566	0.570
CIFAR-10	ResNet50	0.596	0.523	0.522	0.555	0.556	<b>0.511</b>	0.530
CIFAR-10	VGG11_bn	0.633	0.579	0.517	0.635	0.620	<b>0.506</b>	0.523
CIFAR-10	VGG13_bn	0.563	0.536	<b>0.443</b>	0.572	0.510	0.488	0.461
CIFAR-10	VGG16_bn	0.542	0.617	0.478	0.548	0.550	<b>0.477</b>	0.518
CIFAR-10	VGG19_bn	0.578	0.526	<b>0.443</b>	0.514	0.531	0.460	0.495
CIFAR-100	MobileNetV2_x0_5	0.364	0.325	0.289	<b>0.260</b>	0.270	0.266	0.893
CIFAR-100	MobileNetV2_x1_0	0.337	0.295	0.266	0.264	0.262	<b>0.254</b>	0.815
CIFAR-100	MobileNetV2_x1_4	0.305	0.297	0.254	0.246	0.251	<b>0.245</b>	0.737
CIFAR-100	ResNet20	0.357	0.338	0.287	<b>0.270</b>	0.274	0.276	1.001
CIFAR-100	ResNet32	0.383	0.309	0.285	<b>0.262</b>	0.267	0.274	0.956
CIFAR-100	ResNet44	0.398	0.303	0.283	<b>0.263</b>	0.274	0.270	0.897
CIFAR-100	ResNet56	0.391	0.285	0.275	<b>0.260</b>	0.272	0.262	0.873
CIFAR-100	ShuffleNetV2_x0_5	0.379	0.312	0.288	<b>0.261</b>	0.272	0.276	0.999
CIFAR-100	ShuffleNetV2_x1_0	0.343	0.315	0.281	<b>0.253</b>	0.269	0.266	0.849
CIFAR-100	ShuffleNetV2_x1_5	0.302	0.290	0.259	0.259	0.265	<b>0.255</b>	0.773
CIFAR-100	ShuffleNetV2_x2_0	0.274	0.291	0.256	0.252	0.261	<b>0.245</b>	0.738
CIFAR-100	VGG11_bn	0.399	0.286	0.272	0.271	0.285	<b>0.262</b>	0.678
CIFAR-100	VGG13_bn	0.359	0.262	0.272	0.264	0.267	<b>0.254</b>	0.639
CIFAR-100	VGG16_bn	0.448	0.244	0.249	0.252	0.259	<b>0.244</b>	0.645
CIFAR-100	VGG19_bn	0.462	<b>0.237</b>	0.244	0.254	0.266	0.246	0.696
ImageNet	EfficientNet_b8	0.035	0.025	<b>0.022</b>	0.023	0.024	0.023	0.042
ImageNet	MobileNetV2_120d	0.036	0.034	0.030	<b>0.030</b>	0.030	0.030	0.080
ImageNet	RepVGG_b3	0.028	0.030	<b>0.027</b>	0.028	0.028	0.028	0.067
ImageNet	VGG19_bn	0.032	0.036	<b>0.031</b>	0.032	0.032	0.032	0.091

Таблица 7: *swECE*, % – *Classwise Expected Calibration Error* (меньше – лучше), 15 бинов группа 1

Датасет	Модель	До калибровки	Hist-binning	Isotonic	T-scaling	V-scaling	V-scaling-b	M-scaling-b
CIFAR-10	DenseNet121 (CE)	0.948	0.478	0.530	0.548	0.485	<b>0.455</b>	0.461
CIFAR-10	DenseNet121 (FL 1)	0.755	0.487	<b>0.376</b>	0.462	0.430	0.416	0.540
CIFAR-10	DenseNet121 (FL 2)	0.514	0.488	0.424	0.462	<b>0.419</b>	0.431	0.428
CIFAR-10	DenseNet121 (FL 3)	0.524	0.489	<b>0.474</b>	0.532	0.508	0.483	0.517
CIFAR-10	DenseNet121 (LS 0.05)	0.576	0.376	0.446	0.514	0.410	<b>0.317</b>	0.392
CIFAR-10	ResNet110 (CE)	0.990	0.491	0.547	0.550	0.495	<b>0.449</b>	0.476
CIFAR-10	ResNet110 (FL 1)	0.804	0.483	<b>0.404</b>	0.517	0.511	0.449	0.458
CIFAR-10	ResNet110 (FL 2)	0.660	0.470	0.411	0.486	0.453	<b>0.408</b>	0.438
CIFAR-10	ResNet110 (FL 3)	0.505	0.436	<b>0.400</b>	0.500	0.417	0.418	0.425
CIFAR-10	ResNet110 (LS 0.05)	0.673	0.497	0.488	0.617	0.505	<b>0.420</b>	0.431
CIFAR-10	ResNet50 (CE)	0.941	0.469	0.493	0.524	0.454	0.435	<b>0.428</b>
CIFAR-10	ResNet50 (FL 1)	0.836	0.520	0.465	0.519	0.465	<b>0.464</b>	0.470
CIFAR-10	ResNet50 (FL 2)	0.625	0.506	0.457	0.511	0.485	0.465	<b>0.455</b>
CIFAR-10	ResNet50 (FL 3)	0.524	0.525	<b>0.429</b>	0.531	0.528	0.464	0.513
CIFAR-10	ResNet50 (LS 0.05)	0.766	0.520	0.455	0.634	0.525	0.459	<b>0.440</b>
CIFAR-10	Wide-ResNet-26-10 (CE)	0.699	0.399	0.388	0.440	0.404	<b>0.371</b>	0.382
CIFAR-10	Wide-ResNet-26-10 (FL 1)	0.611	0.442	0.399	0.412	0.402	0.400	<b>0.375</b>
CIFAR-10	Wide-ResNet-26-10 (FL 2)	0.479	0.443	0.436	0.462	<b>0.428</b>	0.437	0.429
CIFAR-10	Wide-ResNet-26-10 (FL 3)	0.523	0.401	0.377	0.452	0.400	<b>0.373</b>	0.407
CIFAR-10	Wide-ResNet-26-10 (LS 0.05)	0.869	0.417	0.424	0.502	0.458	<b>0.400</b>	0.415
CIFAR-100	DenseNet121 (CE)	0.458	<b>0.210</b>	0.239	0.258	0.252	0.226	0.688
CIFAR-100	DenseNet121 (FL 1)	0.364	<b>0.231</b>	0.249	0.267	0.261	0.237	0.695
CIFAR-100	DenseNet121 (FL 2)	0.280	0.278	0.241	0.256	0.252	<b>0.239</b>	0.694
CIFAR-100	DenseNet121 (FL 3)	0.254	0.283	0.248	0.252	0.258	<b>0.244</b>	0.698
CIFAR-100	DenseNet121 (LS 0.05)	0.315	0.223	0.238	0.252	0.223	<b>0.206</b>	0.668
CIFAR-100	ResNet110 (CE)	0.433	<b>0.183</b>	0.233	0.252	0.254	0.233	0.676
CIFAR-100	ResNet110 (FL 1)	0.372	0.231	0.243	0.262	0.257	<b>0.229</b>	0.669
CIFAR-100	ResNet110 (FL 2)	0.321	0.253	0.246	0.254	0.254	<b>0.243</b>	0.660
CIFAR-100	ResNet110 (FL 3)	0.281	0.257	0.245	0.258	0.258	<b>0.241</b>	0.671
CIFAR-100	ResNet110 (LS 0.05)	0.299	<b>0.217</b>	0.245	0.253	0.250	0.221	0.667
CIFAR-100	ResNet50 (CE)	0.412	<b>0.215</b>	0.250	0.259	0.259	0.240	0.683
CIFAR-100	ResNet50 (FL 1)	0.337	0.251	0.250	0.250	0.253	<b>0.243</b>	0.674
CIFAR-100	ResNet50 (FL 2)	0.282	0.272	0.251	0.250	0.244	<b>0.234</b>	0.692
CIFAR-100	ResNet50 (FL 3)	0.256	0.274	0.250	0.252	0.245	<b>0.238</b>	0.707
CIFAR-100	ResNet50 (LS 0.05)	0.271	<b>0.222</b>	0.239	0.258	0.243	0.225	0.640
CIFAR-100	Wide-ResNet-26-10 (CE)	0.372	<b>0.198</b>	0.229	0.230	0.241	0.219	0.645
CIFAR-100	Wide-ResNet-26-10 (FL 1)	0.264	0.238	0.229	0.223	0.219	<b>0.210</b>	0.624
CIFAR-100	Wide-ResNet-26-10 (FL 2)	0.218	0.245	0.211	0.216	0.215	<b>0.208</b>	0.611
CIFAR-100	Wide-ResNet-26-10 (FL 3)	0.226	0.260	0.216	0.228	0.220	<b>0.215</b>	0.596
CIFAR-100	Wide-ResNet-26-10 (LS 0.05)	0.239	0.222	0.229	0.240	0.238	<b>0.219</b>	0.608
TinyImageNet	ResNet50 (CE)	0.250	0.218	0.216	<b>0.201</b>	0.213	0.208	0.671
TinyImageNet	ResNet50 (FL 1)	0.218	0.226	<b>0.199</b>	0.205	0.216	0.212	0.684
TinyImageNet	ResNet50 (FL 2)	0.205	0.228	0.208	<b>0.203</b>	0.214	0.204	0.678
TinyImageNet	ResNet50 (FL 3)	0.203	0.227	<b>0.202</b>	0.204	0.217	0.209	0.677
TinyImageNet	ResNet50 (LS 0.05)	0.231	0.210	0.203	<b>0.200</b>	0.206	0.203	0.628

Таблица 8: *swECE*, % – *Classwise Expected Calibration Error* (меньше – лучше), 15 бинов  
группа 2

Датасет	Модель	До калибровки	Hist-binning	Isotonic	T-scaling	V-scaling	V-scaling-b	M-scaling-b
CIFAR-10	DenseNet121	42.22	32.98	80.26	41.59	<b>25.41</b>	29.82	36.27
CIFAR-10	DenseNet161	25.30	38.11	<b>16.86</b>	27.21	24.37	26.92	34.27
CIFAR-10	DenseNet169	20.25	34.25	<b>16.18</b>	22.95	41.38	36.91	26.38
CIFAR-10	GoogleNet	19.85	24.06	24.77	<b>13.08</b>	16.88	25.35	42.19
CIFAR-10	InceptionV3	31.42	80.60	<b>17.31</b>	31.74	20.06	33.00	28.17
CIFAR-10	MobileNetV2	33.59	68.23	25.32	<b>24.74</b>	32.21	74.59	27.27
CIFAR-10	ResNet18	34.79	28.21	<b>17.80</b>	28.45	76.02	24.15	24.30
CIFAR-10	ResNet34	23.94	42.79	<b>18.42</b>	24.47	31.98	25.98	21.92
CIFAR-10	ResNet50	26.73	41.10	19.27	24.68	24.24	<b>16.52</b>	31.25
CIFAR-10	VGG11_bn	23.38	16.46	16.86	23.40	18.33	<b>16.37</b>	25.19
CIFAR-10	VGG13_bn	33.53	25.74	<b>14.47</b>	36.17	40.39	25.12	23.99
CIFAR-10	VGG16_bn	43.19	34.06	<b>19.88</b>	43.57	26.82	22.98	20.03
CIFAR-10	VGG19_bn	35.49	33.63	<b>18.37</b>	22.27	36.65	24.40	19.50
CIFAR-100	MobileNetV2_x0_5	39.98	22.95	14.67	43.49	<b>9.70</b>	11.54	89.36
CIFAR-100	MobileNetV2_x1_0	28.71	25.03	17.36	9.74	<b>7.37</b>	9.69	77.00
CIFAR-100	MobileNetV2_x1_4	25.60	25.06	12.64	<b>6.32</b>	8.72	10.38	90.57
CIFAR-100	ResNet20	38.15	23.61	13.66	12.52	<b>8.89</b>	14.32	76.15
CIFAR-100	ResNet32	32.21	22.11	13.88	<b>9.12</b>	9.37	9.23	84.30
CIFAR-100	ResNet44	32.68	28.18	15.00	<b>9.09</b>	10.82	12.42	92.21
CIFAR-100	ResNet56	30.81	61.69	14.19	10.67	<b>7.78</b>	9.63	82.18
CIFAR-100	ShuffleNetV2_x0_5	23.82	21.63	12.26	8.51	<b>7.89</b>	8.38	76.58
CIFAR-100	ShuffleNetV2_x1_0	24.66	24.33	18.31	13.27	14.08	<b>10.62</b>	82.94
CIFAR-100	ShuffleNetV2_x1_5	24.47	24.70	14.58	17.98	13.47	<b>12.31</b>	71.59
CIFAR-100	ShuffleNetV2_x2_0	93.58	24.84	13.84	27.37	27.23	<b>12.18</b>	83.28
CIFAR-100	VGG11_bn	40.53	29.29	20.59	15.36	<b>13.28</b>	14.15	47.91
CIFAR-100	VGG13_bn	34.00	33.38	18.11	16.34	13.75	<b>13.11</b>	51.88
CIFAR-100	VGG16_bn	48.47	45.52	16.72	<b>12.39</b>	13.18	15.35	76.81
CIFAR-100	VGG19_bn	51.11	38.46	16.52	17.08	14.98	<b>13.73</b>	54.69
ImageNet	EfficientNet_b8	44.80	22.83	<b>12.03</b>	93.37	22.61	17.02	55.00
ImageNet	MobileNetV2_120d	12.31	18.22	6.16	<b>3.75</b>	5.92	5.65	63.64
ImageNet	RepVGG_b3	11.15	19.16	<b>7.36</b>	10.09	10.68	14.01	61.53
ImageNet	VGG19_bn	8.33	20.24	8.72	6.40	5.48	<b>4.71</b>	72.88

Таблица 9: MCE, % – Maximum Calibration Error, (меньше – лучше), 15 бинов группа 1



Датасет	Модель	До калибровки	Hist-binning	Isotonic	T-scaling	V-scaling	V-scaling-b	M-scaling-b
CIFAR-10	DenseNet121 (CE)	46.58	53.58	23.62	<b>22.26</b>	29.52	23.21	67.72
CIFAR-10	DenseNet121 (FL 1)	36.54	37.23	26.98	29.38	31.21	70.77	<b>22.20</b>
CIFAR-10	DenseNet121 (FL 2)	27.80	35.64	<b>10.22</b>	66.85	29.08	28.61	29.06
CIFAR-10	DenseNet121 (FL 3)	77.08	38.19	38.07	76.59	74.49	<b>19.89</b>	23.57
CIFAR-10	DenseNet121 (LS 0.05)	55.74	56.99	80.80	70.26	57.18	66.81	<b>40.70</b>
CIFAR-10	ResNet110 (CE)	47.15	50.61	35.38	<b>25.12</b>	25.90	27.26	31.14
CIFAR-10	ResNet110 (FL 1)	73.35	61.93	26.03	49.35	<b>19.64</b>	42.96	29.91
CIFAR-10	ResNet110 (FL 2)	26.15	30.54	24.24	<b>23.77</b>	25.80	32.68	28.42
CIFAR-10	ResNet110 (FL 3)	<b>25.15</b>	30.68	29.37	38.39	30.89	69.55	30.64
CIFAR-10	ResNet110 (LS 0.05)	55.53	83.03	<b>20.67</b>	59.80	58.54	59.94	48.80
CIFAR-10	ResNet50 (CE)	42.08	55.72	22.08	20.49	32.80	<b>18.27</b>	31.52
CIFAR-10	ResNet50 (FL 1)	37.23	73.04	<b>22.43</b>	31.58	73.41	26.62	34.54
CIFAR-10	ResNet50 (FL 2)	<b>25.00</b>	41.04	74.60	67.95	76.43	29.61	32.46
CIFAR-10	ResNet50 (FL 3)	28.99	32.00	<b>11.89</b>	19.15	24.35	31.04	30.76
CIFAR-10	ResNet50 (LS 0.05)	50.21	45.06	<b>21.05</b>	74.74	51.06	76.52	43.41
CIFAR-10	Wide-ResNet-26-10 (CE)	48.03	63.54	<b>25.41</b>	30.04	30.41	31.41	32.78
CIFAR-10	Wide-ResNet-26-10 (FL 1)	26.49	48.07	<b>18.55</b>	75.41	24.17	31.02	21.96
CIFAR-10	Wide-ResNet-26-10 (FL 2)	33.49	74.05	<b>23.92</b>	31.05	29.04	24.23	37.53
CIFAR-10	Wide-ResNet-26-10 (FL 3)	28.18	19.14	18.52	69.02	31.10	<b>17.94</b>	29.90
CIFAR-10	Wide-ResNet-26-10 (LS 0.05)	39.10	36.02	<b>19.03</b>	31.45	71.21	36.22	42.35
CIFAR-100	DenseNet121 (CE)	54.14	29.97	21.75	28.70	<b>12.36</b>	12.84	77.88
CIFAR-100	DenseNet121 (FL 1)	35.37	36.84	17.62	16.51	14.52	<b>14.35</b>	86.25
CIFAR-100	DenseNet121 (FL 2)	26.13	24.50	15.21	<b>12.86</b>	14.74	15.88	82.62
CIFAR-100	DenseNet121 (FL 3)	14.76	23.33	11.81	12.16	13.74	<b>9.81</b>	76.96
CIFAR-100	DenseNet121 (LS 0.05)	46.99	30.43	22.79	60.42	12.61	<b>11.28</b>	75.69
CIFAR-100	ResNet110 (CE)	58.32	43.75	19.58	24.80	19.10	<b>17.70</b>	85.79
CIFAR-100	ResNet110 (FL 1)	38.23	41.78	20.14	18.67	20.87	<b>17.51</b>	70.51
CIFAR-100	ResNet110 (FL 2)	30.27	30.83	15.95	19.63	18.86	<b>14.13</b>	89.28
CIFAR-100	ResNet110 (FL 3)	25.44	23.25	16.91	21.06	16.78	<b>15.19</b>	69.21
CIFAR-100	ResNet110 (LS 0.05)	40.00	30.48	<b>15.85</b>	30.16	20.27	20.47	89.53
CIFAR-100	ResNet50 (CE)	47.19	47.37	20.20	<b>16.26</b>	20.44	22.76	83.57
CIFAR-100	ResNet50 (FL 1)	34.78	32.35	21.41	16.26	<b>13.78</b>	15.34	53.71
CIFAR-100	ResNet50 (FL 2)	23.83	25.69	14.62	<b>14.00</b>	15.24	16.00	91.02
CIFAR-100	ResNet50 (FL 3)	14.00	20.36	<b>9.20</b>	12.66	12.36	10.70	89.46
CIFAR-100	ResNet50 (LS 0.05)	31.28	29.37	94.39	23.55	21.02	<b>18.71</b>	69.93
CIFAR-100	Wide-ResNet-26-10 (CE)	55.83	46.57	21.84	15.99	14.89	<b>14.20</b>	83.06
CIFAR-100	Wide-ResNet-26-10 (FL 1)	27.40	30.07	16.22	<b>12.96</b>	14.48	13.07	72.31
CIFAR-100	Wide-ResNet-26-10 (FL 2)	16.16	27.35	<b>11.15</b>	12.62	13.02	26.94	88.77
CIFAR-100	Wide-ResNet-26-10 (FL 3)	<b>9.90</b>	24.61	13.33	12.65	16.52	44.60	80.98
CIFAR-100	Wide-ResNet-26-10 (LS 0.05)	26.84	32.39	20.92	27.45	24.19	<b>18.73</b>	75.74
TinyImageNet	ResNet50 (CE)	33.75	21.46	26.91	17.26	<b>15.41</b>	17.65	80.79
TinyImageNet	ResNet50 (FL 1)	18.63	14.14	17.73	<b>9.08</b>	12.43	17.18	78.34
TinyImageNet	ResNet50 (FL 2)	9.53	14.57	9.68	<b>7.69</b>	9.86	10.83	71.59
TinyImageNet	ResNet50 (FL 3)	6.39	14.29	10.00	<b>6.21</b>	7.30	11.51	77.58
TinyImageNet	ResNet50 (LS 0.05)	26.59	15.09	<b>7.08</b>	13.56	17.30	18.21	77.05

Таблица 10: MCE, % – Maximum Calibration Error; (меньше – лучше), 15 бинов группа 2

## С Скоринговые ошибки

Датасет	Модель	До калибровки	Hist-binning	Isotonic	T-scaling	V-scaling	V-scaling-b	M-scaling-b
CIFAR-10	DenseNet121	0.257	0.427	0.354	0.257	0.258	<b>0.255</b>	0.256
CIFAR-10	DenseNet161	0.261	0.495	0.285	0.262	0.255	<b>0.253</b>	0.281
CIFAR-10	DenseNet169	0.245	0.559	0.309	0.245	<b>0.242</b>	0.242	0.258
CIFAR-10	GoogleNet	0.246	0.290	0.300	0.241	0.241	0.239	<b>0.235</b>
CIFAR-10	InceptionV3	0.265	0.550	0.349	0.266	0.264	<b>0.264</b>	0.264
CIFAR-10	MobileNetV2	0.241	0.494	0.309	0.239	0.239	<b>0.237</b>	0.239
CIFAR-10	ResNet18	0.269	0.616	0.327	0.269	0.265	<b>0.263</b>	0.269
CIFAR-10	ResNet34	0.269	0.508	0.317	0.265	0.261	<b>0.260</b>	0.265
CIFAR-10	ResNet50	0.255	0.589	0.289	0.253	0.252	<b>0.251</b>	0.258
CIFAR-10	VGG11_bn	0.257	0.410	0.342	0.257	0.255	<b>0.252</b>	0.254
CIFAR-10	VGG13_bn	0.207	0.487	0.249	0.207	0.205	<b>0.202</b>	0.206
CIFAR-10	VGG16_bn	0.233	0.522	0.276	0.232	0.230	<b>0.229</b>	0.237
CIFAR-10	VGG19_bn	0.248	0.553	0.291	0.245	0.244	<b>0.242</b>	0.250
CIFAR-100	MobileNetV2_x0_5	1.210	4.128	1.738	<b>1.066</b>	1.073	1.083	15.290
CIFAR-100	MobileNetV2_x1_0	1.102	4.019	1.480	<b>0.979</b>	0.986	0.986	13.881
CIFAR-100	MobileNetV2_x1_4	0.997	3.823	1.499	<b>0.908</b>	0.911	0.909	12.531
CIFAR-100	ResNet20	1.267	4.445	1.771	<b>1.155</b>	1.161	1.164	17.232
CIFAR-100	ResNet32	1.370	4.573	1.762	<b>1.148</b>	1.155	1.162	16.467
CIFAR-100	ResNet44	1.358	4.350	1.656	<b>1.097</b>	1.104	1.110	15.459
CIFAR-100	ResNet56	1.340	3.933	1.711	<b>1.069</b>	1.076	1.075	15.020
CIFAR-100	ShuffleNetV2_x0_5	1.342	4.479	1.795	<b>1.196</b>	1.199	1.206	16.835
CIFAR-100	ShuffleNetV2_x1_0	1.200	4.205	1.760	<b>1.089</b>	1.098	1.103	14.203
CIFAR-100	ShuffleNetV2_x1_5	1.109	3.727	1.594	<b>1.052</b>	1.053	1.054	12.794
CIFAR-100	ShuffleNetV2_x2_0	1.018	3.610	1.613	<b>0.992</b>	0.999	0.997	12.425
CIFAR-100	VGG11_bn	1.541	3.978	1.840	<b>1.259</b>	1.275	1.270	4.707
CIFAR-100	VGG13_bn	1.320	3.361	1.642	<b>1.106</b>	1.118	1.117	4.230
CIFAR-100	VGG16_bn	1.677	3.162	1.584	<b>1.142</b>	1.148	1.144	5.757
CIFAR-100	VGG19_bn	1.836	3.034	1.621	<b>1.158</b>	1.162	1.158	7.711
ImageNet	EfficientNet_b8	0.656	2.778	1.432	<b>0.572</b>	0.581	0.664	5.554
ImageNet	MobileNetV2_120d	0.946	4.282	1.917	<b>0.894</b>	0.900	0.931	10.508
ImageNet	RepVGG_b3	0.823	3.751	1.795	0.815	<b>0.811</b>	0.871	9.225
ImageNet	VGG19_bn	1.034	4.892	2.100	<b>1.017</b>	1.021	1.040	13.665

Таблица 11: Negative Log-Likelihood (меньше – лучше), группа 1

Датасет	Модель	До калибровки	Hist-binning	Isotonic	T-scaling	V-scaling	V-scaling-b	M-scaling-b
CIFAR-10	DenseNet121 (CE)	0.422	0.398	0.213	0.216	0.209	0.206	<b>0.198</b>
CIFAR-10	DenseNet121 (FL 1)	0.230	0.508	0.271	0.190	0.185	<b>0.182</b>	0.193
CIFAR-10	DenseNet121 (FL 2)	0.186	0.548	0.278	0.181	0.178	<b>0.178</b>	0.182
CIFAR-10	DenseNet121 (FL 3)	0.193	0.369	0.312	0.194	0.191	<b>0.191</b>	0.206
CIFAR-10	DenseNet121 (LS 0.05)	0.306	0.389	0.334	0.306	0.298	<b>0.293</b>	0.302
CIFAR-10	ResNet110 (CE)	0.512	0.454	0.227	0.230	0.224	<b>0.222</b>	0.228
CIFAR-10	ResNet110 (FL 1)	0.234	0.547	0.285	0.181	0.181	<b>0.177</b>	0.182
CIFAR-10	ResNet110 (FL 2)	0.195	0.477	0.261	0.179	0.177	<b>0.174</b>	0.176
CIFAR-10	ResNet110 (FL 3)	0.185	0.478	0.252	0.183	0.178	<b>0.177</b>	0.185
CIFAR-10	ResNet110 (LS 0.05)	0.301	0.434	0.302	0.301	0.294	<b>0.289</b>	0.290
CIFAR-10	ResNet50 (CE)	0.428	0.516	0.207	0.212	0.207	<b>0.203</b>	0.203
CIFAR-10	ResNet50 (FL 1)	0.253	0.604	0.246	0.193	0.187	<b>0.184</b>	0.188
CIFAR-10	ResNet50 (FL 2)	0.191	0.530	0.292	0.181	0.177	<b>0.176</b>	0.186
CIFAR-10	ResNet50 (FL 3)	0.190	0.485	0.237	0.188	0.186	<b>0.185</b>	0.199
CIFAR-10	ResNet50 (LS 0.05)	0.293	0.575	0.310	0.292	0.285	<b>0.280</b>	0.296
CIFAR-10	Wide-ResNet-26-10 (CE)	0.273	0.400	0.171	0.156	0.156	<b>0.153</b>	0.154
CIFAR-10	Wide-ResNet-26-10 (FL 1)	0.181	0.454	0.209	0.158	0.158	<b>0.157</b>	0.162
CIFAR-10	Wide-ResNet-26-10 (FL 2)	0.161	0.447	0.244	0.159	0.157	<b>0.156</b>	0.160
CIFAR-10	Wide-ResNet-26-10 (FL 3)	0.158	0.334	0.206	0.157	0.152	<b>0.151</b>	0.161
CIFAR-10	Wide-ResNet-26-10 (LS 0.05)	0.224	0.389	0.279	0.217	0.211	<b>0.207</b>	0.230
CIFAR-100	DenseNet121 (CE)	2.063	2.325	1.564	1.200	1.183	<b>1.173</b>	11.759
CIFAR-100	DenseNet121 (FL 1)	1.188	3.153	1.582	1.031	1.012	<b>1.006</b>	11.888
CIFAR-100	DenseNet121 (FL 2)	0.948	3.645	1.437	0.928	0.917	<b>0.913</b>	11.761
CIFAR-100	DenseNet121 (FL 3)	0.903	3.609	1.484	<b>0.902</b>	0.903	0.905	11.792
CIFAR-100	DenseNet121 (LS 0.05)	1.435	2.492	1.899	1.375	1.356	<b>1.349</b>	11.259
CIFAR-100	ResNet110 (CE)	1.843	2.391	1.382	1.074	1.076	<b>1.070</b>	11.560
CIFAR-100	ResNet110 (FL 1)	1.165	2.900	1.493	0.969	0.964	<b>0.962</b>	11.421
CIFAR-100	ResNet110 (FL 2)	1.006	3.352	1.507	0.942	0.937	<b>0.935</b>	11.200
CIFAR-100	ResNet110 (FL 3)	0.941	3.254	1.507	0.922	0.918	<b>0.913</b>	11.475
CIFAR-100	ResNet110 (LS 0.05)	1.363	2.603	1.847	1.325	1.325	<b>1.313</b>	11.344
CIFAR-100	ResNet50 (CE)	1.582	2.785	1.538	1.089	1.092	<b>1.084</b>	11.625
CIFAR-100	ResNet50 (FL 1)	1.094	3.426	1.625	0.969	0.969	<b>0.965</b>	11.530
CIFAR-100	ResNet50 (FL 2)	0.951	3.301	1.436	0.924	<b>0.920</b>	0.920	11.816
CIFAR-100	ResNet50 (FL 3)	0.897	3.491	1.514	0.893	0.887	<b>0.885</b>	12.042
CIFAR-100	ResNet50 (LS 0.05)	1.230	3.014	1.727	1.220	1.216	<b>1.205</b>	10.760
CIFAR-100	Wide-ResNet-26-10 (CE)	1.437	2.430	1.354	<b>0.979</b>	0.990	0.982	10.962
CIFAR-100	Wide-ResNet-26-10 (FL 1)	0.898	2.725	1.293	0.846	0.845	<b>0.844</b>	10.631
CIFAR-100	Wide-ResNet-26-10 (FL 2)	0.780	3.031	1.245	0.780	<b>0.779</b>	0.780	10.419
CIFAR-100	Wide-ResNet-26-10 (FL 3)	0.759	3.206	1.327	0.755	<b>0.752</b>	0.755	10.240
CIFAR-100	Wide-ResNet-26-10 (LS 0.05)	1.109	2.754	1.549	1.109	1.106	<b>1.095</b>	10.395
TinyImageNet	ResNet50 (CE)	2.325	6.905	3.478	<b>2.199</b>	2.213	2.214	21.369
TinyImageNet	ResNet50 (FL 1)	2.180	6.833	3.411	<b>2.160</b>	2.170	2.167	22.083
TinyImageNet	ResNet50 (FL 2)	2.033	6.626	3.158	<b>2.032</b>	2.048	2.042	21.973
TinyImageNet	ResNet50 (FL 3)	2.038	6.768	3.004	<b>2.036</b>	2.057	2.047	21.756
TinyImageNet	ResNet50 (LS 0.05)	2.334	5.121	3.108	<b>2.129</b>	2.142	2.141	18.609

Таблица 12: Negative Log-Likelihood (меньше – лучше), группа 2

Датасет	Модель	До калибровки	Hist-binning	Isotonic	T-scaling	V-scaling	V-scaling-b	M-scaling-b
CIFAR-10	DenseNet121	0.102	0.106	<b>0.099</b>	0.102	0.102	0.102	0.101
CIFAR-10	DenseNet161	0.102	0.107	<b>0.098</b>	0.103	0.101	0.101	0.104
CIFAR-10	DenseNet169	0.098	0.106	<b>0.095</b>	0.099	0.098	0.098	0.100
CIFAR-10	GoogleNet	<b>0.109</b>	0.112	0.109	0.109	0.110	0.109	0.110
CIFAR-10	InceptionV3	0.108	0.115	<b>0.105</b>	0.109	0.109	0.108	0.109
CIFAR-10	MobileNetV2	0.102	0.106	<b>0.099</b>	0.103	0.103	0.102	0.103
CIFAR-10	ResNet18	0.117	0.124	<b>0.113</b>	0.116	0.115	0.115	0.117
CIFAR-10	ResNet34	0.113	0.116	<b>0.106</b>	0.111	0.110	0.110	0.111
CIFAR-10	ResNet50	0.107	0.112	<b>0.102</b>	0.106	0.105	0.105	0.106
CIFAR-10	VGG11_bn	0.118	0.122	<b>0.115</b>	0.118	0.118	0.117	0.118
CIFAR-10	VGG13_bn	0.092	0.102	<b>0.091</b>	0.093	0.093	0.092	0.094
CIFAR-10	VGG16_bn	0.100	0.108	<b>0.097</b>	0.100	0.099	0.099	0.101
CIFAR-10	VGG19_bn	0.102	0.109	<b>0.098</b>	0.101	0.101	0.100	0.102
CIFAR-100	MobileNetV2_x0_5	0.431	0.469	0.413	<b>0.404</b>	0.406	0.408	0.892
CIFAR-100	MobileNetV2_x1_0	0.387	0.431	0.373	<b>0.365</b>	0.367	0.368	0.814
CIFAR-100	MobileNetV2_x1_4	0.352	0.402	0.341	<b>0.336</b>	0.337	0.337	0.736
CIFAR-100	ResNet20	0.459	0.511	0.448	<b>0.438</b>	0.440	0.441	1.001
CIFAR-100	ResNet32	0.453	0.493	0.431	<b>0.420</b>	0.423	0.424	0.956
CIFAR-100	ResNet44	0.441	0.475	0.411	<b>0.403</b>	0.405	0.406	0.897
CIFAR-100	ResNet56	0.429	0.451	0.397	<b>0.392</b>	0.394	0.395	0.873
CIFAR-100	ShuffleNetV2_x0_5	0.468	0.510	0.450	<b>0.442</b>	0.443	0.445	0.996
CIFAR-100	ShuffleNetV2_x1_0	0.413	0.451	0.401	<b>0.392</b>	0.395	0.396	0.847
CIFAR-100	ShuffleNetV2_x1_5	0.384	0.426	0.377	<b>0.373</b>	0.373	0.374	0.770
CIFAR-100	ShuffleNetV2_x2_0	0.359	0.408	0.354	<b>0.352</b>	0.353	0.353	0.736
CIFAR-100	VGG11_bn	0.455	0.473	0.424	<b>0.415</b>	0.419	0.419	0.673
CIFAR-100	VGG13_bn	0.406	0.425	0.381	<b>0.373</b>	0.375	0.375	0.629
CIFAR-100	VGG16_bn	0.450	0.439	0.386	<b>0.382</b>	0.383	0.382	0.633
CIFAR-100	VGG19_bn	0.456	0.436	0.380	0.379	0.378	<b>0.377</b>	0.672
ImageNet	EfficientNet_b8	0.222	0.251	0.217	<b>0.215</b>	0.217	0.219	0.407
ImageNet	MobileNetV2_120d	0.323	0.379	0.324	<b>0.314</b>	0.319	0.322	0.776
ImageNet	RepVGG_b3	0.283	0.332	0.286	<b>0.282</b>	0.285	0.289	0.655
ImageNet	VGG19_bn	0.354	0.423	0.363	<b>0.353</b>	0.358	0.361	0.900

Таблица 13: Brier Score (меньше – лучше) группа 1

Датасет	Модель	До калибровки	Hist-binning	Isotonic	T-scaling	V-scaling	V-scaling-b	M-scaling-b
CIFAR-10	DenseNet121 (CE)	0.094	0.094	<b>0.081</b>	0.084	0.082	0.082	0.082
CIFAR-10	DenseNet121 (FL 1)	0.086	0.092	<b>0.079</b>	0.081	0.080	0.080	0.084
CIFAR-10	DenseNet121 (FL 2)	0.081	0.089	<b>0.079</b>	0.080	0.079	0.079	0.080
CIFAR-10	DenseNet121 (FL 3)	0.089	0.091	<b>0.088</b>	0.089	0.088	0.088	0.090
CIFAR-10	DenseNet121 (LS 0.05)	0.102	0.102	<b>0.091</b>	0.103	0.102	0.101	0.100
CIFAR-10	ResNet110 (CE)	0.097	0.098	0.086	0.087	0.086	0.086	<b>0.086</b>
CIFAR-10	ResNet110 (FL 1)	0.086	0.088	0.078	0.079	0.078	<b>0.078</b>	0.078
CIFAR-10	ResNet110 (FL 2)	0.082	0.087	0.079	0.079	0.078	<b>0.078</b>	0.079
CIFAR-10	ResNet110 (FL 3)	0.083	0.088	0.081	0.082	<b>0.079</b>	0.079	0.082
CIFAR-10	ResNet110 (LS 0.05)	0.103	0.103	<b>0.092</b>	0.103	0.102	0.101	0.099
CIFAR-10	ResNet50 (CE)	0.093	0.098	0.084	0.085	0.084	<b>0.083</b>	0.084
CIFAR-10	ResNet50 (FL 1)	0.091	0.098	0.083	0.084	0.083	<b>0.083</b>	0.083
CIFAR-10	ResNet50 (FL 2)	0.083	0.091	0.080	0.081	0.079	<b>0.079</b>	0.081
CIFAR-10	ResNet50 (FL 3)	0.085	0.092	0.084	0.084	0.084	<b>0.084</b>	0.088
CIFAR-10	ResNet50 (LS 0.05)	0.102	0.106	<b>0.094</b>	0.102	0.101	0.101	0.099
CIFAR-10	Wide-ResNet-26-10 (CE)	0.069	0.070	<b>0.061</b>	0.061	0.061	0.061	0.061
CIFAR-10	Wide-ResNet-26-10 (FL 1)	0.070	0.077	0.067	<b>0.067</b>	0.068	0.068	0.067
CIFAR-10	Wide-ResNet-26-10 (FL 2)	0.071	0.078	<b>0.068</b>	0.070	0.071	0.070	0.071
CIFAR-10	Wide-ResNet-26-10 (FL 3)	0.068	0.072	<b>0.067</b>	0.069	0.068	0.067	0.069
CIFAR-10	Wide-ResNet-26-10 (LS 0.05)	0.076	0.078	<b>0.072</b>	0.077	0.076	0.076	0.077
CIFAR-100	DenseNet121 (CE)	0.446	0.413	0.368	0.372	0.364	<b>0.364</b>	0.687
CIFAR-100	DenseNet121 (FL 1)	0.385	0.394	0.351	0.354	0.348	<b>0.347</b>	0.694
CIFAR-100	DenseNet121 (FL 2)	0.348	0.389	<b>0.336</b>	0.339	0.336	0.336	0.693
CIFAR-100	DenseNet121 (FL 3)	0.336	0.391	0.337	0.336	0.336	<b>0.336</b>	0.697
CIFAR-100	DenseNet121 (LS 0.05)	0.406	0.405	<b>0.378</b>	0.387	0.378	0.378	0.667
CIFAR-100	ResNet110 (CE)	0.421	0.393	0.347	0.349	0.346	<b>0.345</b>	0.675
CIFAR-100	ResNet110 (FL 1)	0.375	0.384	0.333	0.336	0.333	<b>0.332</b>	0.669
CIFAR-100	ResNet110 (FL 2)	0.358	0.387	<b>0.334</b>	0.339	0.337	0.336	0.658
CIFAR-100	ResNet110 (FL 3)	0.346	0.379	<b>0.331</b>	0.337	0.334	0.333	0.670
CIFAR-100	ResNet110 (LS 0.05)	0.386	0.401	<b>0.366</b>	0.372	0.372	0.371	0.665
CIFAR-100	ResNet50 (CE)	0.411	0.406	0.355	0.353	0.353	<b>0.353</b>	0.682
CIFAR-100	ResNet50 (FL 1)	0.365	0.393	0.341	0.337	0.335	<b>0.334</b>	0.673
CIFAR-100	ResNet50 (FL 2)	0.346	0.388	0.337	0.337	<b>0.335</b>	0.335	0.691
CIFAR-100	ResNet50 (FL 3)	0.331	0.382	0.332	0.329	0.328	<b>0.328</b>	0.706
CIFAR-100	ResNet50 (LS 0.05)	0.365	0.390	<b>0.351</b>	0.359	0.357	0.356	0.639
CIFAR-100	Wide-ResNet-26-10 (CE)	0.365	0.364	0.316	<b>0.310</b>	0.312	0.311	0.645
CIFAR-100	Wide-ResNet-26-10 (FL 1)	0.304	0.337	0.294	0.291	<b>0.290</b>	0.290	0.623
CIFAR-100	Wide-ResNet-26-10 (FL 2)	0.287	0.331	0.284	0.286	0.284	<b>0.284</b>	0.611
CIFAR-100	Wide-ResNet-26-10 (FL 3)	0.281	0.336	<b>0.280</b>	0.283	0.281	0.281	0.596
CIFAR-100	Wide-ResNet-26-10 (LS 0.05)	0.326	0.363	<b>0.317</b>	0.325	0.323	0.322	0.607
TinyImageNet	ResNet50 (CE)	0.677	0.720	0.661	<b>0.646</b>	0.652	0.654	1.324
TinyImageNet	ResNet50 (FL 1)	0.648	0.714	0.650	<b>0.641</b>	0.645	0.646	1.352
TinyImageNet	ResNet50 (FL 2)	0.620	0.688	0.630	<b>0.620</b>	0.627	0.627	1.343
TinyImageNet	ResNet50 (FL 3)	0.624	0.707	0.634	<b>0.623</b>	0.631	0.631	1.340
TinyImageNet	ResNet50 (LS 0.05)	0.645	0.682	0.617	<b>0.613</b>	0.620	0.621	1.229

Таблица 14: Brier Score (меньше – лучше) группа 2